

KV cache 최적화 기술 다관점 평가 보고서

DeepSeek-V2 MLA(SW 압축) vs ITME(HW 메모리 확장) — 데이터센터·클라우드 장문맥 LLM 서버
판교 9반 2조 · 김동욱, 김민정, 김태동, 박규리, 이재겸, 임동건 · 2026-10-07

SUMMARY

- **TRL 추정(공개 정보 기반):** DeepSeek-V2 MLA와 ITME 개별 기술은 모두 **TRL 4-6**이다. MLA는 DeepSeek-V2 내 구현·내부 평가, ITME는 FPGA 프로토타입·제한 워크로드 평가가 근거이나, 실서비스 운영·독립 재현·상용 채택은 확인되지 않는다 [1, p.6] [1, p.15] [2, p.2] [2, p.11].
- **MLA:** 모델 아키텍처에서 KV를 저랭크 잠재 벡터로 압축한다. 메모리 효율(D3)은 적합이나, 품질 보존(D4)과 운영 안정성(D5)은 근거 부족이다 [1, p.7] [1, p.8].
- **ITME:** CXL-hybrid 계층과 프리페칭으로 장문맥 KV를 배치·이동한다. 서비스 성능(D2)·메모리 효율(D3)은 적합 신호이나, 원격 계층 지연·통합·운영 검증이 제약이다 [2, p.2] [2, p.7] [2, p.9].
- 시장·이해관계자 평가는 엇갈린다. MLA는 생태계 지원이 긍정이나 채택은 근거 부족이고, ITME는 CXL 계열 성장 신호가 있으나 ITME 개별 상용화는 근거 부족이다 [W5] [W6] [W21] [W1].
- 두 기술은 경쟁적 단일 대안이 아니라, KV 저장량을 줄이는 모델 계층 접근과 남은 대용량 상태를 확장 계층에 배치 하는 인프라 접근으로서 보완 가능성이 있다. 다만 결합 효과의 직접 근거는 없다.

1. 분석 배경

KV cache는 생성 추론에서 과거 토큰의 key-value를 보관해 어텐션 계산을 돕는 상태이며, 일반 MHA에서는 이 저장량이 최대 배치와 시퀀스 길이를 제한하는 병목으로 설명된다 [1, p.7]. 데이터센터·클라우드 장문맥 서버에서는 대규모 동시 요청, 비용 민감성, 문맥 길이 민감성이 겹쳐 HBM 점유와 KV 이동·재계산 문제가 커진다는 것을 설계 기준으로 삼았다 [D].

본 평가는 하나의 우승 기술을 고르지 않는다. MLA는 저장해야 할 KV 자체를 줄이고, ITME는 대용량 데이터를 계층적으로 배치·이동하므로 작동 계층과 측정 단위가 다르다. 따라서 기술 성숙도, 시장성, 이해관계자, 도메인 적용성에서의 근거와 공백을 병기한다.

표 1. KV cache 규모 예시 (Llama-3.1-70B, FP16 — 설계 산출물 A-2) [D]

문맥 길이	요청 1건 KV cache	동시 8건	GPU HBM 80GB(≈74.5GiB) 대비(1건)
8K	2.5 GiB	20 GiB	약 3.4%
128K	40 GiB	320 GiB	약 53.7%
1M	320 GiB	2,560 GiB	약 429.5%

산식: 토큰당 KV = 레이어 $80 \times$ KV head 8(GQA) $\times$ head dim 128 $\times$ (K, V) 2 $\times$ FP16 2B = 327,680B = 320KiB.
요청 1건 = 문맥 토큰 수 $\times$ 320KiB (8K = 8,192 토큰, 128K = 131,072 토큰, 1M = 1,048,576 토큰). HBM 대비 비율은 80GB = 80×10^9 B $\approx$ 74.5GiB를 분모로 계산했다(설계서 A-2의 3%·50%·400%는 GiB/GB 단위를 혼용한 근사치라 여기서 바로잡음) [D].

2. 기술 선정

선정 방식

- 2안: 조 토의 후 직접 선정을 적용했다. 선정 기준은 KV cache 병목과의 직접성, 데이터센터·클라우드 장문맥 서버 관련성, 그리고 소프트웨어·하드웨어의 서로 다른 대응 계층을 함께 검토할 수 있는지였다 [D].

선정 결과

- **DeepSeek-V2 MLA:** key-value를 저장원 잠재 벡터로 공동 압축하도록 어텐션 구조를 재설계한 소프트웨어 접근이다 [1, p.6] [1, p.7]. 기존 비-MLA 모델에 사후 적용하는 경로는 공개 근거로 확인되지 않아 도입성은 조건부로 둔다 [D].

- **ITME**: CXL 기반 DRAM-NVMe hybrid memory와 프리페칭으로 장문맥 KV 및 모델 가중치를 확장 계층에 배치하는 하드웨어 접근이다 [2, p.1] [2, p.2].

비선택 후보의 비교·평가는 검증된 입력이 있을 때에만 다룬다. 본 보고서에서는 InfiniGen과 CXL-PNM을 ITME 한계의 교차 확인용 베이스라인으로만 사용한다 [3, p.4] [4, p.4].

표 2. 비선택 후보와 사유 (설계 단계 팀 판단 — 설계 산출물 A-4) [D]

후보	진영	비선택 사유	RAG 문서 활용
InfiniGen	HW	호스트 메모리 오프로딩으로 신규 메모리 인프라 없이 SW 관리 성격이 강함	O (ITME 비교용 베이스라인)
CXL-PNM	HW	연산까지 메모리 측으로 옮기는 확장형 접근으로, '공간 확장' 자체의 대표성은 ITME가 더 직접적	O (ITME 비교용 베이스라인)
KIVI	SW	사후 양자화의 대표 베이스라인이나 공개 채택 근거가 연구·라이브러리 수준	X (선택 검토만)
TurboQuant	SW	재학습 없이 적용 가능한 최신 양자화이나 공식 상용화 근거가 제한적	X (선택 검토만)

3. 기술 개요

구분	DeepSeek-V2 MLA	ITME
진영	모델·어텐션 소프트웨어	CXL-hybrid 메모리·프리페칭 하드웨어
작동 계층	모델 아키텍처	메모리·스토리지 계층
핵심 접근	KV 저랭크 공동 압축 및 잠재 벡터 캐시 [1, p.7]	CXL-hybrid memory, DMA 프리페칭, 계층 배치 [2, p.1] [2, p.2]
저자 보고 효과	KV cache 감소 및 효율적 추론 목표 [1, p.6]	NVMe-oF 기준선 대비 처리량 1.80배 향상 보고 [2, p.2]
전제조건	MLA 구조를 포함한 모델·서빙 구현	CXL-hybrid memory, RDMA, 호스트 스테이징, 프리페칭 통합 [2, p.2]
한계	MLA 단독 장문맥 품질·운영 안정성 근거 부족	원격 계층 지연, 경합, 상용 운영 근거 부족 [2, p.7] [2, p.11]

MLA

MLA는 추론 중 완전한 key·value 대신 압축 잠재 벡터를 캐시하고, 일부 투영을 다른 행렬에 흡수해 명시적 key·value 계산을 줄이는 구조다 [1, p.7]. 저자 보고 결과는 DeepSeek-V2 전체 구성의 결과이므로 MLA 단독 효과로 귀속할 수 없다.

ITME

ITME는 압축 기술이 아니라 대용량·예측 가능한 모델 가중치와 장문맥 KV를 CXL-hybrid 확장 계층에 두고 데이터 이동을 연산과 중첩하는 기술이다 [2, p.2] [2, p.4]. 저자 보고 기준 ITME는 재계산 기준 대비 5턴에서 **1.81배** 속도 향상과 NVMe-oF 기준선 대비 처리량 **1.80배** 향상을 보고했다 [2, p.9] [2, p.2].

4. 관점별 평가

4.1 기술 성숙도(TRL)

기술	TRL 추정(공개 정보 기반)	판단 근거 요약
DeepSeek-V2 MLA	개별 기술 TRL: 4-6. 판정: 제공 논문은 DeepSeek-V2 내 MLA 구현, 내부 벤치마크 및 저자 보고 성능을 보여 주므로 통합 구현·검증 단계로는 평가할 수 있다. 그러나 논문만으로 실제 서비스 운영 또는 상용 채택은 확인되지 않아 TRL 7-9는 부여하지 않는다. [1, p.6] [1, p.7] [1, p.8] [1, p.15] [1, p.21] 계열 TRL: 4-6. 판정: 제공 자료는 MLA가 속한 attention/KV-cache 최적화 계열의 별도 상용 제품군 또는 실제 서비스 채택을 직접 문서화하지 않는다. 따라서 MLA 구현·검증 근거를 넘어서 계열을 TRL 7-9로 판정할 근거가 없다. 이 값은 MLA 자체와 일반 계열의 상용 성숙도를 동일시하지 않는 보수적 상한이다.	TRL 기준 적용: 논문 기반 근거는 구현·검증을 지지할 수 있으나 실운용 채택을 지지하지 않는다. MLA의 저자 보고 결과는 DeepSeek-V2 전체 구성의 결과이며 MLA 단독의 외부 검증 또는 운영 채택 증거가 아니다. 공식 GitHub 발췌문은 FlashMLA가 DeepSeek-V3/V3.2-Exp 모델을 지원한다고 설명하지만, 제공 범위에서 이것이 DeepSeek-V2 MLA 원 아키텍처의 상용 서비스 채택을 직접 입증하지 않으므로 TRL 7-9 판정 근거로 사용하지 않았다.
ITME	개별 기술 TRL: 4-6. 판정: ITME 자체는 hardware prototype 및 ITME(FPGA) 비교 평가, Llama-3.1 기반 워크로드 검증이 문서화되어 있어 프로토타입/유사 운용 조건 검증 단계로 평가할 수 있다. 실서비스 배포·상용 운용 근거가 없으므로 TRL 7-9는 부여하지 않는다. [2, p.2] [2, p.9] [2, p.11] 계열 TRL: 4-6. 판정: 제공 자료는 CXL 기반 메모리 확장 및 pooling을 핵심 기술로 서술하고 CXL-hybrid memory와 PCIe Gen5 SSD/CMM을 사용한 feasibility를 제시하지만, CXL 메모리 모듈 일반의 제품 출시나 상용 운영 사례는 문서화하지 않는다. 따라서 CXL 계열의 일반적 상용 성숙도를 ITME의 FPGA 프로토타입 근거만으로 TRL 7-9로 판정할 수 없다. [2, p.4] [2, p.11]	TRL 기준 적용: FPGA hardware prototype과 제한된 모델·데이터셋 기반 평가는 TRL 4-6의 구현/검증 근거이다. CXL 일반 관련 웹 발췌문은 ITME 개별 아키텍처의 출시 또는 상용 서비스 채택을 문서화하지 않으며, 일부는 ITME/CXL과 직접 관련 없는 메모리 제품 기사이므로 TRL 근거로 사용하지 않았다.

DeepSeek-V2 MLA

개별 기술은 공개 논문에서 DeepSeek-V2 내 MLA 구현과 내부 평가가 확인되어 TRL 4-6으로 추정한다 [1, p.6] [1, p.7] [1, p.15]. 그러나 이는 DeepSeek-V2 전체 구성의 저자 보고이며, 실제 서비스 운영 또는 독립 검증은 확인되지 않는다. MLA가 속한 attention/KV-cache 최적화 계열도 별도 상용 제품군·운영 채택이 문서화되지 않아 동일하게 보수적으로 TRL 4-6으로 둔다. FlashMLA의 DeepSeek-V3/V3.2-Exp 지원은 DeepSeek-V2 MLA의 상용 운영 증거가 아니다 [W9].

ITME

ITME 개별 기술은 FPGA 프로토타입과 Llama-3.1 기반 평가가 문서화되어 TRL 4-6으로 추정한다 [2, p.2] [2, p.9] [2, p.11]. CXL 메모리 확장 계열 역시 논문상 feasibility 근거는 있으나, 제공 자료만으로 CXL 일반의 상용 운영 성숙도를 판정할 수 없어 TRL 4-6으로 둔다 [2, p.4] [2, p.11].

두 판단은 모두 **공개 정보 기반 추정**이며, CXL 제품군 일반의 성숙도를 ITME 개별 기술의 성숙도로 전가하지 않았다.

4.2 시장성

평가 대상	DeepSeek-V2 MLA	ITME
시장 규모·성장성	근거 부족	긍정
상용화·채택 현황	근거 부족	근거 부족
생태계 지지	긍정	근거 부족
종합	근거 부족	근거 부족
근거	[W17] [W22] [W19] [W5] [W6]	[W21] [W1] [W25]

DeepSeek-V2 MLA

MLA 기능 자체는 vLLM의 MLA backend 및 DeepSeek-style MLA 문서, SGLang의 MLA 최적화 발표으로 생태계 지지 긍정 신호가 있다 [W5] [W6] [W19]. 반면 제공 시장자료는 기업용 또는 일반 LLM 시장이지 MLA가 속한 추론 최적화 시장을 직접 정의하지 않으며, DeepSeek-V2 MLA 자체의 유료 서비스·독립 고객 운영 사례도 근거 부족이다 [W17] [W22]. 따라서 종합은 근거 부족이다.

ITME

CXL memory controller IC 시장과 AI 추론·KV cache 수요의 성장 전망은 ITME 상위 계열의 긍정 신호다 [W21]. CXL pooling-sharing 활용 논의도 확인된다 [W1] [W25]. 그러나 이 근거는 ITME 개별 제품, 고객 채택, 공식 통합 또는 매출을 직접 보여주지 않는다. CXL 시장과 소프트웨어 추론 최적화 시장은 서로 달라 시장 규모만으로 비교할 수 없으며, ITME 종합은 근거 부족이다.

4.3 이해관계자

평가 대상	DeepSeek-V2 MLA	ITME
경쟁 진영	근거 부족	근거 부족
도입 기업·개발자	혼재	근거 부족
투자 업계	근거 부족	우려
종합	근거 부족	혼재
근거	[W13] [W11]	[W14] [W23]

DeepSeek-V2 MLA

경쟁 진영과 투자 업계의 직접 발언은 근거 부족이다. 개발자·도입 기업 관점은 혼재다. 한 커뮤니티 사용자는 두 p5 H100 노드에서 SGLang의 DeepSeek 지원이 당시 vLLM보다 더 좋고 빨랐다고 경험을 제시했으나, 재현 조건이 완전하지 않은 커뮤니티 의견이다 [W13]. 독립 기술 작성자는 weight absorption과 decoupled RoPE가 수학·특수 최적화 코드의 복잡성을 높인다고 비판했다 [W11]. 실제 도입기업의 운영 경험은 확인되지 않았다.

ITME

경쟁 진영과 실제 도입기업·개발자의 ITME 직접 발언은 근거 부족이다. 투자 업계 신호는 우려다. Gartner 및 Greyhound Research 관련 발언은 CXL memory pooling이 단기 구조적 메모리 제약의 해소책은 아니며 대규모 전환에는 시간이 걸린다고 평가했다 [W23]. 반면 삼성의 자사 평가는 CXL memory pool이 더 큰 KV cache footprint를 수용하면서 성능을 유지했다고 제시한다 [W14]. 양측은 ITME 자체가 아니라 CXL 계열에 관한 견해이므로 ITME 종합은 혼재다.

4.4 도메인 적용성(D1-D7)

평가항목	MLA 판정	MLA 근거	ITME 판정	ITME 근거
D1 워크로드 수용 능력	조건부	[1, p.1] [1, p.21]	조건부	[2, p.9]
D2 서비스 성능	조건부	[1, p.16]	적합	[2, p.2] [2, p.9]
D3 메모리 자원 효율	적합	[1, p.1] [1, p.16]	적합	[2, p.9]
D4 품질·정보 보존	근거 부족	[1, p.1] [1, p.21]	근거 부족	[2, p.9]
D5 운영 안정성	근거 부족	[1, p.5] [1, p.6]	조건부	[2, p.7] [2, p.9]
D6 도입·확장 용이성	조건부	[1, p.7] [1, p.12] [1, p.28]	조건부	[2, p.1] [2, p.2] [2, p.9]
D7 비용 효율성	조건부	[1, p.1] [1, p.16]	조건부	[2, p.1] [2, p.9]

DeepSeek-V2 MLA

D3은 적합이다. MLA는 KV를 잠재 벡터로 압축하며, 저자 보고 기준 DeepSeek-V2 전체는 DeepSeek 67B 대비 KV cache를 93.3% 줄였다고 제시한다 [1, p.7] [1, p.1]. D1·D2·D6·D7은 조건부다. 모델은 128K 문맥을 지원하고, 저자들은 FP8 변환·KV 평균 6비트 양자화 조건에서 8 H800 노드의 생성 처리량이 50K tokens/s를 넘었다고 보고했지만, MLA 단독의 동시성·TTFT·총비용은 확인되지 않는다 [1, p.4] [1, p.16]. D4·D5는 장문맥 품질 보존과 다중 요청 안정성의 직접 근거가 부족하다.

ITME

D2·D3은 적합이다. 저자 보고 기준 ITME는 5턴에서 재계산 대비 1.81배 속도 향상과 NVMe-oF 대비 1.80배 처리량 향상을 제시하며 [2, p.9] [2, p.2], ITME 구성은 Host/CXL staging으로 10GB를 오프로딩해 안정적 16GB GPU footprint를 유지한다고 보고한다 [2, p.9]. D1·D5·D6·D7은 조건부이며 CXL·RDMA·프리페칭 통합과 원격 지연·경합을 검증해야 한다 [2, p.2] [2, p.7] [2, p.10]. D4는 생성 품질·장문맥 정보 보존 측정이 없어 근거 부족이다.

5. 종합 의견

관점 매트릭스

관점	MLA	ITME
TRL	4-6: 구현·내부 평가, 운영 채택 미확인	4-6: FPGA 검증, 상용 운영 미확인
시장성	근거 부족: 생태계 지지 긍정, 채택 미확인	근거 부족: CXL 성장 신호, ITME 채택 미확인
이해관계자	근거 부족: 개발자 반응 흔재	흔재: CXL 기대와 전환 우려 병존
도메인	D3 적합, D1·D2·D6·D7 조건부, D4·D5 근거 부족	D2·D3 적합, D1·D5·D6·D7 조건부, D4 근거 부족

관점 간 일치

- 두 기술 모두 구현·실험 근거는 있으나 실운영·독립 재현·총비용 근거가 부족하다는 점에서 TRL과 도메인 평가가 일치한다 [1, p.15] [2, p.11].
- 두 기술 모두 품질·정보 보존(D4)의 직접 검증은 근거 부족이다.

상충표: MLA

쟁점	관점 A 평가	관점 B 평가	엇갈리는 이유
생태계와 성숙도	시장: 생태계 지지 긍정 [W5] [W6]	TRL: 4-6	프레임워크 지원은 DeepSeek-V2 MLA의 실운영 증거가 아님
메모리와 운영	D3: 적합 [1, p.7]	D5: 근거 부족	KV 축소가 동시 요청 안정성을 직접 입증하지 않음

상충표: ITME

쟁점	관점 A 평가	관점 B 평가	엇갈리는 이유
계열 성장과 개별 성숙도	시장: CXL 성장 신호 긍정 [W21]	TRL: 4-6	계열 시장 전망은 ITME 제품화 증거가 아님
성과와 운영	D2·D3: 적합 [2, p.2] [2, p.9]	D5·D6: 조건부	제한 워크로드 성능이 경합·통합 위험을 포괄하지 않음

MLA는 KV 저장량을 줄이고 ITME는 남은 상태를 계층에 배치하므로 보완 계층이다. 직접 결합 실험은 근거 부족이다.

6. 시사점

이해관계자	도입 전 확인 과제
클라우드 사업자	동일 장문맥·동시성 조건에서 HBM·호스트·CXL 사용량, TTFT와 토큰 지연 p50/p95/p99, 캐시 미스·경합·장애 복구를 측정
모델 개발사	MLA 단독의 장문맥 품질·회상, 비·MLA 체크포인트 전환 또는 재학습 필요성, 서빙 커널 호환성을 검증

이해관계자	도입 전 확인 과제
메모리·HW 벤더	CXL-hybrid memory, RDMA, 스테이징·프리페처 API의 통합 범위와 원격 지연 은닉 조건을 확인
투자자	CXL 계열 성장 전망과 ITME 개별 제품화·고객 도입을 분리하고, MLA 생태계 지원과 실제 고객 채택을 분리해 점검

관점별 평가는 달라진다. MLA는 모델 변경을 전제로 메모리 점유를 줄이는 데 직접적이지만 일반적 사후 도입 경로가 불명확하다. ITME는 모델 변경 없이 확장 계층을 제공할 수 있으나 하드웨어·네트워크·프리페칭 통합에 의존한다 [1, p.7] [2, p.2]. 두 접근을 함께 평가하려면 동일 워크로드에서 KV bytes/token, 계층별 점유, 품질, 지연, 총비용을 통일된 기준선으로 측정해야 한다. 공개 근거만으로 결합 효과나 단일 도입안을 제시할 수 없다.

7. 한계점

자료 기준 시점: 웹 자료 검색·검증일 2026-10-07 (Tavily 검색 결과 기준). 이후 공개된 발표·제품 정보는 반영되지 않았다.

- 모든 TRL 판정은 논문, 프로토타입·특허성 자료, 상용 발표를 포함한 **공개 정보만으로 한 추정**이다. 발표·논문과 실제 채택 사이에는 시차가 있으며, TRL 4-6 구간의 비공개 통합·장기 운영 정보 공백이 남는다.
- 근거 부족: MLA·ITME 모두 독립 재현, 실제 데이터센터 운영, 고객 채택, 장기 안정성, p95/p99 지연, 총소유비용 자료가 부족하다. MLA는 추론 최적화 시장의 직접 정의와 MLA 단독 품질·전환 경로가 부족하다. ITME는 개별 제품 출시·채택, 직접 생태계, 품질 보존 및 CXL/RDMA 경합 자료가 부족하다.
- 도메인 D1의 제한 GPU 메모리별 최대 동시 요청 수와 워크로드 정의도 근거 부족이다. ITME의 저자 보고 **1.81배** 속도 향상은 재계산 기준·5턴 조건이며 [2, p.9], **1.80배** 처리량 향상은 NVMe-oF 기반 분리형 스토리지 기준선 조건이다 [2, p.2]. 일반 서비스 성과로 확대 해석하지 않았다.
- 확증편향 방지 조치로 InfiniGen·CXL-PNM 베이스라인 논문을 사용해 ITME를 교차 확인했고 [3, p.4] [4, p.4], 두 기술을 동일 보고 형식으로 병기했으며, 종합 단계는 이미 검증된 Evidence만 사용하도록 제한했다.
- 이 조치에도 출처 범위와 저자 보고 의존성은 남는다. 따라서 본 보고서는 순위·우승·단일 추천을 제시하지 않는다.

근거 공백 (Supervisor 기록)

- 근거 부족: tech: 기술 성숙도(TRL) 재조사 2회 후에도 근거 부족 — 제공된 발췌문에는 ‘메모리 계층(memory hierarchy)’ 자체의 계층 구조, 저장 장치 간 데이터 이동, 또는 관리 정책에 대한 설명은 없습니다.; 제공된 발췌문에는 온라인 RL 프레임워크의 구체적 알고리즘, 하이퍼파라미터, 하드웨어 구성, 데이터셋 규모, 학습 단계 수 및 재현 가능한 실행 설정이 없습니다.; 제공된 발췌문에는 표준 벤치마크 평가의 전체 결과 수치 및 각 벤치마크의 상세 프롬프트·샷 설정이 완전하게
- 근거 부족: market: 시장성 재조사 2회 후에도 근거 부족 — MLA가 속한 LLM 추론 서버·추론 최적화 시장을 직접 정의하는 신뢰 가능한 시장조사기관 웹 자료(조사기관, 기준연도, 전망연도, 단위, CAGR 포함); ITME가 속한 CXL 메모리 시장의 시장조사기관 웹 자료(조사기관별 기준연도, 전망연도, 단위, CAGR 포함); DeepSeek-V2 MLA 자체를 명시하는 유료 서비스, 독립 고객사 도입 또는 실제 운영 사례
- 근거 부족: stakeholder: 이해관계자 재조사 2회 후에도 근거 부족 — ITME 이해관계자 관련 고유 출처 최소 2개 및 최신 시도 기준의 직접 근거; OpenAI, Google, Anthropic, Meta 등 경쟁 진영의 MLA 또는 DeepSeek MLA 계열에 대한 식별 가능한 직접 발언; ITME 자체에 대한 경쟁사 또는 경쟁 기술 제공자의 대안·한계·병행 가능성 관련 명시적 발언
- 근거 부족: domain: 도메인 적용성 재조사 2회 후에도 근거 부족 — ‘D1 워크로드’의 정의 및 해당 워크로드의 모델/서빙 구성; 제한된 GPU 메모리의 구체적 용량과 GPU 종류; GPU 메모리 제약별 수용 가능한 동시 요청 수
- 근거 부족: tech: 종합 단계에서 추가 근거 요청, 재조사 한도 소진 — 근거 부족
- 근거 부족: market: 종합 단계에서 추가 근거 요청, 재조사 한도 소진 — 근거 부족
- 근거 부족: stakeholder: 종합 단계에서 추가 근거 요청, 재조사 한도 소진 — 근거 부족
- 근거 부족: domain: 종합 단계에서 추가 근거 요청, 재조사 한도 소진 — 근거 부족

표 7. 증거 균형표 (중복 제거 후 수집·검증된 Evidence 수)

구분	DeepSeek-V2 MLA	ITME	HW 베이스라인(InfiniGen·CXL-PNM)
기술 조사·논문 청크	33	47	8

구분	DeepSeek-V2 MLA	ITME	HW 베이스라인(InfiniGen·CXL-PNM)
기술 조사 · 웹 문서	6	4	0
시장 · 웹 문서	6	4	0
이해관계자 · 웹 문서	4	3	0
도메인 · 논문 청크	40	44	0
합계	89	102	8

REFERENCE

- [1] DeepSeek-AI (2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv preprint arXiv:2405.04434, p.1, p.4, p.5, p.6, p.7, p.8, p.12, p.15, p.16, p.21, p.28.
- [2] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J. (SK hynix) (2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv preprint arXiv:2606.12556, p.1, p.2, p.4, p.7, p.9, p.10, p.11.
- [3] Lee, W., Lee, J., Seo, J., & Sim, J. (Seoul National University) (2024). InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management. arXiv preprint arXiv:2406.19707, p.4.
- [4] Kim, D., Lee, M., Kim, J., Kwon, H., Jeong, H., Park, S.-S., et al. (Hanyang University, Samsung Electronics) (2025). Scalable Processing-Near-Memory for 1M-Token LLM Inference: CXL-Enabled KV-Cache Management Beyond GPU Limits. arXiv preprint arXiv:2511.00321, p.4.
- [W5] docs.vllm.ai (게시일 미확인). mla_attention - vLLM. docs.vllm.ai, https://docs.vllm.ai/en/latest/api/vllm/model_executor/layers/attention/mla_attention
- [W6] docs.vllm.ai (게시일 미확인). Attention Backend Feature Support - vLLM. docs.vllm.ai, https://docs.vllm.ai/en/stable/design/attention_backends
- [W21] mordorintelligence.com (Tue, 28 Jul 2026 00:00:00 GMT). CXL Memory Controller IC Market Size, Share & 2031 Growth Trends Report. mordorintelligence.com, <https://www.mordorintelligence.com/industry-reports/cxl-memory-controller-ic-market>
- [W1] computeexpresslink.org (게시일 미확인). Breaking Boundaries in Memory: Highlights from AI Infra Summit and SDC 2025 - Compute Express Link. computeexpresslink.org, <https://computeexpresslink.org/blog/breaking-boundaries-in-memory-highlights-from-ai-infra-summit-and-sdc-2025-4198>
- [W9] github.com (Wed, 09 Sep 2026 12:00:00 GMT). GitHub - deepseek-ai/FlashMLA: FlashMLA: Efficient Multi-head Latent Attention Kernels · GitHub. github.com, <https://github.com/deepseek-ai/FlashMLA>
- [W17] gminsights.com (Thu, 01 Oct 2026 10:00:00 GMT). Enterprise LLM Market Size, Forecasts Report 2026-2035. gminsights.com, <https://www.gminsights.com/industry-analysis/enterprise-llm-market>
- [W22] mordorintelligence.com (Fri, 11 Sep 2026 00:00:00 GMT). Large Language Model Market Size, Growth & Outlook | Industry Report 2031. mordorintelligence.com, <https://www.mordorintelligence.com/industry-reports/large-language-model-llm-market>
- [W19] lmsys.org (게시일 미확인). SGLang v0.3 Release: 7x Faster DeepSeek MLA, 1.5x Faster torch.compile, Multi-Image/Video LLaVA-OneVision - LMSYS Org. lmsys.org, <https://www.lmsys.org/blog/2024-09-04-sglang-v0-3>
- [W25] penguinsolutions.com (게시일 미확인). CXL 3.0 vs. CXL 2.0: Advancing Composable AI Infrastructure. penguinsolutions.com, <https://www.penguinsolutions.com/en-us/resources/blog/cxl-30-vs-cxl-20-key-differences-and-benefits>

- [W13] news.ycombinator.com (게시일 미확인). DeepSeek Open Source FlashMLA - MLA Decoding Kernel for Hopper GPUs | Hacker News. news.ycombinator.com, <https://news.ycombinator.com/item?id=43155023>
- [W11] liorsinai.github.io (게시일 미확인). DeepSeek's Multi-Head Latent Attention - Lior Sinai. liorsinai.github.io, <https://liorsinai.github.io/machine-learning/2025/02/22/mla.html>
- [W14] semiconductor.samsung.com (게시일 미확인). Breaking AI Memory Limits with CXL Memory Pooling. semiconductor.samsung.com, <https://semiconductor.samsung.com/news-events/tech-blog/breaking-ai-memory-limits-with-cxl-memory-pooling>
- [W23] networkworld.com (게시일 미확인). Chip wafer shortage will run through 2030 as AI demand overwhelms supply: SK Hynix chief | Network World. networkworld.com, <https://www.networkworld.com/article/4146270/chip-wafer-shortage-will-run-through-2030-as-ai-demand-overwhelms-supply-sk-hynix-chief.html>
- [D] 판교 9반 2조 (2026). RAG-Design 설계 산출물: KV cache 최적화 기술 다관점 평가 (A-2 문제 상황, A-4 선정 사유, C 평가 기준). 내부 설계 문서.