

KV cache 최적화 기술 다관점 평가 보고서

DeepSeek-V2 MLA(SW 압축) vs ITME(HW 메모리 확장) — 데이터센터·클라우드 장문맥 LLM 서버
판교 9반 2조 · 김동욱, 김민정, 김태동, 박규리, 이재겸, 임동건 · 2026-10-07

SUMMARY

- **TRL 추정:** MLA는 공개 저장소의 서버 커널 통합 진술을 근거로 TRL 7, ITME는 FPGA 프로토타입·평가 근거를 바탕으로 TRL 4-6으로 추정된다. 두 판단은 공개 정보 기반 추정이다 [W8] [2, p.10] [2, p.11].
- **도메인:** MLA는 KV cache 표현 축소의 저자 보고 근거가, ITME는 확장 계층과 프리페치의 저자 보고 근거가 있어 모두 조건부 신호가 우세하다. MLA의 종단 간 서버 성능·안정성, ITME의 품질 보존은 각각 근거 부족이다 [1, p.31] [1, p.32] [2, p.2] [2, p.10].
- **관점 차이:** MLA는 생태계 구현 근거가 있으나 시장의 고객 채택 근거는 직접적이지 않다. ITME의 CXL 계열 시장 신호는 존재하지만 ITME 개별 기술의 제품화·고객 운영 근거로 확장할 수 없다 [W3] [W4] [W5] [W13] [W22].
- **관계:** MLA는 모델의 KV 표현을 줄이고, ITME는 남은 KV cache와 가중치의 저장·이동 계층을 확장한다. 같은 병목을 다루되 대체재가 아니라 상이한 계층의 접근이며, 결합 효과는 근거 부족이다.
- 본 평가는 우열이나 단일 도입안을 제시하지 않으며, 데이터센터·클라우드 장문맥 서버이라는 설계 조건에서 관점별 확인 과제를 제시한다 [D].

1. 분석 배경

설계 기준

KV cache는 생성 단계에서 이전 토큰의 Key·Value를 보관해 어텐션 계산을 돕는 상태다. 설계 기준상 그 규모는 레이어 수, attention head 수, 문맥 길이, 동시 사용자·batch, 저장 정밀도에 비례해 증가한다. HBM 점유가 커지면 동시 요청·최대 batch 및 장문맥 요청이 제약되고, GPU 증설, KV 이동·로딩 지연, 폐기 후 재계산 문제가 발생할 수 있다 [D].

평가 도메인은 대규모 동시 요청, 비용 민감성, 문맥 길이 민감성이 겹치는 데이터센터·클라우드 기반 장문맥 LLM 서버이다 [D]. MLA와 ITME는 각각 모델 구조와 메모리 인프라에서 이 병목에 접근하므로, 동일 단위의 성능 우열 대신 기술 성숙도, 시장성, 이해관계자 및 도메인 적용성에서 신호와 한계를 비교한다 [D].

표 1. KV cache 규모 예시 (Llama-3.1-70B, FP16 — 설계 산출물 A-2) [D]

문맥 길이	요청 1건 KV cache	동시 8건	GPU HBM 80GB(≈74.5GiB) 대비(1건)
8K	2.5 GiB	20 GiB	약 3.4%
128K	40 GiB	320 GiB	약 53.7%
1M	320 GiB	2,560 GiB	약 429.5%

산식: 토큰당 KV = 레이어 80 × KV head 8(GQA) × head dim 128 × (K, V) 2 × FP16 2B = 327,680B = 320KiB.
요청 1건 = 문맥 토큰 수 × 320KiB (8K = 8,192 토큰, 128K = 131,072 토큰, 1M = 1,048,576 토큰). HBM 대비 비율은 80GB = 80×10 B ≈ 74.5GiB를 분모로 계산했다(설계서 A-2의 3%·50%·400%는 GiB/GB 단위를 혼용한 근사치라 여기서 바로잡음) [D].

2. 기술 선정

선정 방식과 기준

기술은 2안: 조 토의 후 직접 선정 방식으로 정했다. 평가는 TRL, 시장성, 이해관계자, D1-D7 도메인 기준을 적용하며, 목적은 우승 기술 선정이 아니라 관점별 장점·제약·근거 수준을 드러내는 것이다 [D].

- **DeepSeek-V2 MLA:** Key·Value를 저차원 잠재 벡터로 압축하는 어텐션 구조 재설계로, KV cache 자체를 줄이는 소프트웨어 접근이라는 점에서 선정했다. 기존 모델에 사후 적용하기 어려울 수 있다는 설계상 제약도 함께 검토 대상이다 [D].

- **ITME**: CXL 기반 DRAM-NVMe hybrid memory와 프리페치를 활용하여 원격 메모리 계층을 구성하는 하드웨어 접근이라는 점에서 선정했다. 장문맥·다중 턴 KV cache의 수용과 이동 문제를 검토 대상으로 삼았다 [D].

KIVI와 TurboQuant는 검토 의견으로만 언급되었으며, 제공된 검증 입력에는 비선정 사유를 뒷받침하는 기술 비교 근거가 없다 [D].

표 2. 비선정 후보와 사유 (설계 단계 팀 판단 — 설계 산출물 A-4) [D]

후보	진영	비선정 사유	RAG 문서 활용
InfiniGen	HW	호스트 메모리 오프로딩으로 신규 메모리 인프라 없이 SW 관리 성격이 강함	O (ITME 비교용 베이스라인)
CXL-PNM	HW	연산까지 메모리 측으로 옮기는 확장형 접근으로, '공간 확장' 자체의 대표성은 ITME가 더 직접적	O (ITME 비교용 베이스라인)
KIVI	SW	사후 양자화의 대표 베이스라인이나 공개 채택 근거가 연구·라이브러리 수준	X (선정 검토만)
TurboQuant	SW	재학습 없이 적용 가능한 최신 양자화이나 공식 상용화 근거가 제한적	X (선정 검토만)

3. 기술 개요

구분	DeepSeek-V2 MLA	ITME
진영	모델·추론 소프트웨어	CXL-hybrid-memory 기반 인프라
작동 계층	어텐션의 K·V 표현	GPU·호스트·원격 메모리·저장장치 경로
핵심 접근	K·V 공동 저랭크 잠재 벡터를 저장한다 [1, p.7]	원격 바이트 주소형 메모리, RDMA, 내부 프리페치와 다계층 DMA를 사용한다 [2, p.2] [2, p.8]
저자 보고 효과	MHA 대비 KV cache가 소형 MoE에서 14%, 대형 MoE에서 4%라고 보고했다 [1, p.31] [1, p.32]	NVMe-oF 기준선 대비 처리량 1.80배 향상을 보고했다 [2, p.2]
전제조건	MLA 구조 모델·가중치 및 이를 처리하는 추론 구현이 필요하다 [1, p.28]	CXL-hybrid memory, RDMA, 프리페치 제어 경로가 필요하다 [2, p.2]
한계	제공 근거에 중단 간 처리량·TTFT·운영 안정성 측정값이 없다 [1, p.6] [1, p.31]	I/O 경합 시 지연 청크의 재계산이 발생할 수 있다 [2, p.10]

MLA

MLA는 추론 시 모든 K·V를 저장하는 MHA의 KV cache 부담을 줄이기 위해 K·V 공동 저랭크 압축을 사용한다 [1, p.6] [1, p.7]. 저자 보고 기준, 비교 모델에서 KV cache 요소 수와 일반 벤치마크 결과가 함께 제시되지만, 실제 데이터센터 서버의 지연시간·처리량 수치는 제공되지 않았다 [1, p.31] [1, p.32].

ITME

ITME는 예측 가능한 가중치와 prefix KV cache 접근을 이용해 SSD에서 내부 DRAM cache로, 이어 RDMA·호스트 메모리를 거쳐 GPU로 데이터를 미리 이동하는 구조다 [2, p.2] [2, p.8]. 저자 보고 처리량 결과는 있으나, 원격 계층의 읽기·쓰기 경합과 재계산 조건, 품질 보존 검증 공백을 함께 고려해야 한다 [2, p.10] [2, p.11].

4. 관점별 평가

4.1 기술 성숙도(TRL)

기술	TRL 추정(공개 정보 기반)	판단 근거 요약
DeepSeek-V2 MLA	기술 자체: TRL 7. 제공 웹 근거에서 DeepSeek의 공식 FlashMLA 저장소는 해당 최적화 어텐션 커널이 DeepSeek-V3 및 DeepSeek-V3.2-Exp 모델을 구동한다고 명시한다. 이는 MLA 자체가 모델 서빙용 커널/백엔드에 통합된 운영 근거로 해석할 수 있다. 다만 이 근거만으로 외부 고객 대상 API의 SLA, 배포 규모, 독립 운영 재현까지는 확인되지 않는다 ([W8]). 계열: TRL 7. MLA 계열은 DeepSeek-V3 및 DeepSeek-V3.2-Exp를 구동하는 최적화 커널의 공개 통합 근거가 있다 ([W8]). 다만 계열 전반의 다중 공급자 채택 또는 독립 재현은 제공 근거에서 확인되지 않는다.	기술 자체 판정 기준: 문헌만으로는 구현·검증 수준인 TRL 1-6만 뒷받침할 수 있으나, 공식 GitHub 저장소가 FlashMLA를 DeepSeek-V3 및 DeepSeek-V3.2-Exp를 구동하는 최적화 어텐션 커널이라고 명시한다. 이에 따라 MLA 자체에 대해 모델 서빙 커널 통합·운영 채택이 확인된 것으로 보아 TRL 7로 추정했다 ([W8]). 이는 해당 저장소의 진술에 근거한 판정이며, 상용 API 고객 규모나 독립 사업자의 운영 채택을 뜻하지 않는다. 논문 구현·검증 근거: MLA는 저랭크 K·V 공동 압축으로 추론 시 KV cache 병목을 줄이도록 설계되었고 [1, p.6] [1, p.7], MHA와 비교한 KV cache 및 벤치마크 결과가 보고되었다 [1, p.31] [1, p.32].
ITME	기술 자체: TRL 4-6. FPGA 기반 프로토타입과 실제 시스템 환경에서의 하드웨어 제어 로직·소프트웨어 프리페처 검증이 보고되었고, CMM 기반 평가 플랫폼 및 FPGA 프로토타입의 성능을 비교하였다 [2, p.8] [2, p.10] [2, p.11]. 그러나 ITME 자체의 제품 출시, 실제 서비스 운영, 외부 고객 채택을 문서화한 웹 근거는 제공되지 않았다. 계열: TRL 4-6. 제공 근거는 CXL-hybrid-memory를 이용한 ITME 프로토타입 검증과 상용 SK Hynix CMM·PCIe Gen5 SSD를 사용한 평가를 보여 준다 [2, p.11]. 그러나 제공된 웹 자료는 ITME가 속한 CXL 메모리 계열의 제품 출시 또는 상용 서비스 운영을 직접 문서화하지 않으므로, 계열에 TRL 7-9를 부여할 근거는 부족하다. 이는 ITME 개별 기술의 미상용화와 CXL 계열 일반의 시장 부재를 동일시하는 판단은 아니다.	기술 자체 판정 기준: ITME는 CMM 기반 성능 평가와 FPGA 기반 프로토타입으로 하드웨어 실현 가능성을 검증한 단계이다 [2, p.8] [2, p.10] [2, p.11]. 이 근거는 통합 구현·유사 운영 환경 검증에 해당하므로 TRL 4-6으로 추정했다. ITME 개별 기술의 상용 제품 출시, 실제 서비스 운영, 외부 고객 채택은 제공 PDF 및 웹 자료에서 확인되지 않는다. 계열 판정 기준: 상용 SK Hynix CMM 및 PCIe Gen5 SSD가 ITME 평가에 사용된 사실은 확인되지만 [2, p.11], 이는 ITME의 상용화 증거가 아니다. 또한 제공 웹 자료에는 CXL 메모리 제품 자체의 출시·상용 운영을 직접 확인하는 자료가 없다. 따라서 CXL-hybrid-memory 계열의 TRL 7-9 판정도 보류했다.

공개 정보에 한정한 추정이다. TRL은 기술 성숙도를 1~9 단계로 표현하는 척도이며, 여기서 TRL 7 및 TRL 4-6은 표의 공개 근거 수준을 요약하는 용도로만 사용했다 [W20].

DeepSeek-V2 MLA

기술 자체와 MLA 계열 모두 TRL 7 추정의 직접 근거는 DeepSeek 공식 FlashMLA 저장소가 해당 최적화 커널이 DeepSeek-V3 및 DeepSeek-V3.2-Exp 모델을 구동한다고 밝힌 점이다 [W8]. 즉, 공개된 모델 서빙 커널 통합·구동 진술은 확인된다. 다만 이는 DeepSeek-V2 MLA의 외부 고객 SLA, 배포 규모 또는 독립 재현을 확인하는 자료는 아니다. 논문은 MLA의 저랭크 K·V 공동 압축과 비교 벤치마크를 제시한다 [1, p.6] [1, p.31].

ITME

ITME 자체와 CXL-hybrid-memory 계열은 TRL 4-6으로 추정했다. 근거 수준은 CMM 기반 평가와 FPGA 프로토타입을 통한 하드웨어 제어 로직·소프트웨어 프리페처 검증이다 [2, p.8] [2, p.10] [2, p.11]. 상용 SK hynix CMM과 PCIe Gen5 SSD의 평가 사용은 확인되지만, 이는 ITME의 제품 출시 증거가 아니다 [2, p.11]. 제공 자료로는 ITME 개별 기술의 외부 고객 채택, 운영 규모, 독립 재현은 확인되지 않는다. CXL 제품군 일반의 성숙도와 ITME 개별 설계의 성숙도를 동일시하지 않았다.

4.2 시장성

평가 대상	DeepSeek-V2 MLA	ITME
시장 규모·성장성	긍정	혼재
상용화·채택 현황	긍정	혼재
생태계 지지	긍정	혼재
종합	근거 부족	근거 부족
근거	[W29] [W27] [W3] [W17] [W4] [W5] [W26]	[W23] [W22] [W13] [W28] [W2]

한계: 표의 MLA ‘상용화·채택 현황: 긍정’은 DeepSeek R1/V3의 관측·호스팅 지원을 근거로 한 간접 신호일 뿐, DeepSeek-V2 MLA 기능 자체의 고객 채택을 직접 확인하지 못하므로 해당 판정의 직접성을 제한한다.

DeepSeek-V2 MLA

시장 규모·성장성의 긍정은 LLM 시장 전망 및 MLOps·LLMOps 범위에 서빙·추론 최적화가 포함된다는 상위 시장 신호에 근거한다 [W29] [W27]. 이는 MLA 전용 시장 규모·점유율·성장률은 아니다. 상용화·채택의 긍정은 Amazon Bedrock의 DeepSeek R1/V3 관측 지원과 방화벽 뒤 vLLM 클러스터 호스팅 언급에 근거한 모델·호스팅 신호다 [W3] [W17]. MLA 기능 자체의 고객 채택 증거로 해석할 수 없다. 생태계 지지의 긍정은 vLLM의 MLA backend와 SGLang의 MLA 최적화 구현에 근거한다 [W4] [W5] [W26]. 다만 세 하위 판정 모두 반대 방향의 시장 근거는 제공 자료에서 확인되지 않았으며, 종합은 근거 부족으로 유지한다.

ITME

혼재 신호는 ITME 자체가 아니라 CXL 계열 자료에서 온다. CXL 메모리 풀링·공유의 배포 확대 언급, CXL 제품 전시 및 메모리 확장 전망은 긍정 신호다 [W2] [W13] [W23]. 반면 CXL 시장 자료는 AI 추론·KV cache 수요의 성장 전망을 제시하면서도 ITME 개별 기술의 출시·고객 운영을 확인하지 않는다 [W28]. 따라서 ITME의 시장성 종합은 근거 부족이며, CXL 계열 신호를 ITME 채택으로 확대하지 않는다.

4.3 이해관계자

평가 대상	DeepSeek-V2 MLA	ITME
경쟁 진영	근거 부족	근거 부족
도입 기업·개발자	혼재	근거 부족
투자 업계	근거 부족	혼재
종합	근거 부족	혼재
근거	[W16] [W14] [W15]	[W7] [W31] [W24]

DeepSeek-V2 MLA

개발자·도입 기업 관점은 혼재다. AMD는 MLA decode가 지연을 누적시키는 병목이 될 수 있다고 설명하는 한편, AITER 커널이 vLLM·SGLang에 통합돼 AMD Instinct GPU에서 가속을 제공한다고 안내한다 [W16]. 개발자 커뮤니티에서는 특정 환경에서 SGLang의 DeepSeek 지원이 vLLM보다 더 빠르다는 경험담이 제시됐지만, 이는 독립 벤치마크가 아닌 개인 의견이다 [W14]. 경쟁 진영 및 투자 업계가 MLA 자체를 명시적으로 평가한 직접 자료는 부족하다. SemiAnalysis의 KV cache 절감 설명은 분석 의견이지 투자 판단의 직접 근거는 아니다 [W15]. 따라서 종합은 근거 부족이다.

ITME

ITME 자체에 대한 경쟁사·운영자 직접 발언은 확인되지 않아 해당 항목은 근거 부족이다. 투자 업계의 혼재는 CXL 메모리 계열에 대한 간접 반응이다. Morgan Stanley 전망을 인용한 보도는 메모리 지출 비중 확대 신호를 전하지만 [W7], Gartner 및 Greyhound Research 인용 발언은 CXL 메모리 풀링이 단기 구조적 제약을 제거하지 못할 수 있다고 본다 [W31]. 운영자는 CPU·BIOS·펌웨어·스위치 상호운용성, 소프트웨어·관리 도구, 실부하 성능을 확인해야 한다는 일반 CXL 도입 조언도 제시된다 [W24]. 이는 ITME 개별 기술의 사용자 경험이 아니다.

4.4 도메인 적용성(D1-D7)

평가항목	MLA 판정	MLA 근거	ITME 판정	ITME 근거
D1 워크로드 수용 능력	조건부	[1, p.4] [1, p.32]	조건부	[2, p.9] [2, p.10] [2, p.2]
D2 서비스 성능	근거 부족	[1, p.6] [1, p.5]	조건부	[2, p.10] [2, p.2]
D3 메모리 자원 효율	조건부	[1, p.8] [1, p.32]	조건부	[2, p.2] [2, p.9] [2, p.8]
D4 품질·정보 보존	조건부	[1, p.31] [1, p.32]	근거 부족	[2, p.1] [2, p.3]
D5 운영 안정성	근거 부족	[1, p.6] [1, p.31]	조건부	[2, p.9] [2, p.10]
D6 도입·확장 용이성	조건부	[1, p.28] [1, p.31]	조건부	[2, p.2] [2, p.8]
D7 비용 효율성	조건부	[1, p.32] [1, p.6]	조건부	[2, p.10] [2, p.8]

DeepSeek-V2 MLA

D1·D3·D4·D6·D7은 조건부다. 저자 보고 기준 MLA는 MHA 대비 KV cache 요소 수를 줄였고, 비교 표에는 일반 벤치마크 결과가 제시된다 [1, p.31] [1, p.32]. 이는 메모리 여지와 품질 유지 가능성의 근거지만, 실제 HBM 점유량·동시 요청 수·총비용은 확인되지 않는다. MLA는 별도 어텐션 구조로 문서화돼 있어 도입 시 MLA 모델·가중치와 대응 추론 구현의 호환성을 확인해야 한다 [1, p.28]. D2 서비스 성능과 D5 운영 안정성은 종단 간 처리량·TTFT·경합·장기 운영 측정이 없어 근거 부족이다 [1, p.6] [1, p.31].

ITME

D1·D2·D3·D5·D6·D7은 조건부다. 저자 보고 기준 ITME는 장기 다중 대화 평가에서 원격 CXL-hybrid memory를 활용하고, NVMe-oF 기준선 대비 처리량 향상을 제시했다 [2, p.9] [2, p.2]. 그러나 턴 증가에 따른 I/O 경합은 일부 청크 재계산을 유발할 수 있다 [2, p.10]. CXL-hybrid memory·RDMA·프리티처 API 및 관련 시스템 통합이 필요하다 [2, p.2] [2, p.8]. D4는 출력 품질·장문맥 정보 보존을 직접 측정한 자료가 없어 근거 부족이다 [2, p.1] [2, p.3].

5. 종합 의견

관점	MLA	ITME
TRL	TRL 7 추정: 공개 서빙 커널 통합·구동 진술 [W8]	TRL 4-6 추정: 프로토타입·평가 근거 [2, p.10] [2, p.11]
시장	종합 근거 부족: 생태계 지원은 확인되나 고객 채택은 간접 근거 [W3] [W4]	종합 근거 부족: CXL 계열 신호는 있으나 ITME 직접 근거는 부족 [W2] [W13]
이해관계자	종합 근거 부족: 개발자 관점은 혼재 [W14] [W16]	종합 혼재: 투자자 관점은 CXL 계열 간접 신호 [W7] [W31]
도메인	조건부: 메모리 절감 근거와 운영 성능 공백 병존 [1, p.31] [1, p.32]	조건부: 용량·처리량 저자 보고와 경합 조건 병존 [2, p.2] [2, p.10]

관점 간 일치하는 MLA의 KV 표현 축소와 ITME의 계층형 메모리 확장이라는 작동 원리의 확인에 있다 [1, p.7] [2, p.2]. 다만 시장·이해관계자 관점은 각각 MLA 기능 및 ITME 개별 기술에 대한 직접 채택 자료가 부족해 기술·도메인 근거보다 약하다.

기술	쟁점	관점 A 평가	관점 B 평가	엇갈리는 이유
MLA	커널 통합과 서빙 성능	TRL 7 추정 [W8]	D2 근거 부족 [1, p.6]	커널 구동 진술은 종단 간 처리량·TTFT를 측정하지 않는다.
MLA	생태계와 구현 편차	시장 생태계 긍정 [W4] [W26]	개발자·도입 기업 혼재 [W14] [W16]	지원 존재와 환경별 성능 일관성은 다른 주장이다.
ITME	CXL 계열과 개별 ITME	시장 하위 신호 혼재 [W2] [W13]	TRL 4-6 추정 [2, p.10]	CXL 계열 제품·시장 신호는 ITME 프로토타입의 상용화 증거가 아니다.
ITME	처리량과 운영 경합	D2 조건부 [2, p.2]	D5 조건부 [2, p.10]	저자 보고 처리량과 I/O 경합·재계산 조건이 함께 제시된다.

MLA는 KV 표현량을 줄이고 ITME는 메모리 수용·이동 경로를 확장한다. 따라서 두 접근은 보완 가능한 계층이지만, 실제 결합의 호환성·성능·비용을 검증한 자료는 없다.

6. 시사점

관점별 평가는 달라진다. 모델 개발사는 MLA의 메모리 절감 구조와 생태계 구현을 볼 수 있으나, 기존 모델 전환성과 종단 간 성능을 별도 검증해야 한다. 인프라 운영자는 ITME의 용량 확장 가능성을 볼 수 있으나, 원격 계층 경합과 시스템 통합을 별도 검증해야 한다 [1, p.7] [2, p.2] [2, p.10].

이해관계자	도입 전 확인 과제
클라우드 사업자	동일 장문맥·동시성 조건에서 TTFT, 처리량, tail latency, 요청 실패율 및 장애 복구를 측정한다. MLA의 기능 지원과 고객 채택을 구분하고, ITME의 CXL·RDMA 경합을 측정한다.
모델 개발사	MLA 모델·가중치와 추론 backend 호환성, 기존 checkpoint 전환·재학습 필요 여부, 장문맥 정보 보존을 확인한다 [1, p.28] [W4].

이해관계자	도입 전 확인 과제
메모리·HW 벤더	CXL-hybrid memory, NIC, SSD, 프리퍼처 및 관리 경로의 상호운용성과 일부하 성능을 검증한다 [2, p.2] [W24].
투자자	MLA의 생태계 신호와 직접 고객 채택을 구분하고, CXL 계열 시장 전망과 ITME 개별 기술의 제품화·운영 근거를 분리해 검토한다 [W3] [W23] [W31].

두 기술을 비교할 때는 메모리 절감 요소 수와 원격 계층 처리량을 같은 단위의 우열로 환산하지 말고, 동일 모델·문맥·동시성·인프라·품질 목표에서 별도 측정해야 한다.

7. 한계점

자료 기준 시점: 웹 자료 검색·검증일 2026-10-07 (Tavily 검색 결과 기준). 이후 공개된 발표·제품 정보는 반영되지 않았다.

모든 TRL 판정은 논문, 특허성 연구 자료, 상용화 발표 등 **공개 정보만으로 한 추정**이다. 발표·논문 시점과 실제 고객 채택 사이에는 시차가 있을 수 있으며, 특히 TRL 4-6 구간의 비공개 통합·운영 정보는 확인하기 어렵다. 논문 수치와 성능은 저자 보고 기준이며 독립 재현으로 간주하지 않았다.

관점별 근거 부족

- **시장성:** MLA 전용 시장 규모·점유율, MLA 기능 자체의 고객 채택, 부정·반대 방향의 시장 근거가 부족하다. 특히 R1/V3 관측·호스팅 지원은 DeepSeek-V2 MLA 기능 자체의 채택을 직접 입증하지 않는다 [W3] [W17]. ITME는 개별 제품 출시·고객 운영·시장 규모가 부족하며, CXL 계열 근거를 ITME로 일반화할 수 없다.
- **이해관계자:** MLA의 경쟁사·투자자 직접 발언과 ITME 자체의 경쟁사·운영자·투자자 직접 발언이 부족하다.
- **도메인:** MLA의 실서빙 처리량·TTFT·운영 안정성, ITME의 품질 보존·절대 지연시간·총소유비용, 그리고 두 기술의 통제된 병행 실험이 부족하다.

확증편향을 줄이기 위해 ITME는 HW 베이스라인 논문으로 교차 확인했고, 두 기술에 동일한 보고 형식과 관점 기준을 적용했으며, 종합은 이미 검증된 Evidence로 제한했다. 그럼에도 출처 범위와 공개 정보 공백 때문에 채택 규모, 비용 및 장기 운영성을 확정할 수 없다.

근거 공백 (Supervisor 기록)

- **시장성** — 근거 부족: 종합 단계에서 추가 근거가 필요하다고 판단함; 4.2 시장성 표에서 MLA의 ‘상용화·채택 현황’을 ‘긍정’으로 판정한 근거 [W3]·[W17]은 DeepSeek R1/V3 모델의 관측·호스팅 지원을 말할 뿐 DeepSeek-V2 MLA 기능 자체의 채택을 직접 뒷받침하지 않는다. 본문도 이를 ‘적용 모델 및 기능 지원 근거’로 묶어 MLA 채택 신호로 확장한다. 또한 4.2의 MLA 시장 규모·성장성; MLA: 판정이 긍정 한쪽뿐(반대 방향 근거 미탐색); 4.2의 MLA ‘시장 규모·성장성’, ‘상용화·채택 현황’, ‘생태계 지지’는 모두 ‘긍정’인데, 7장 ‘MLA: 판정이 긍정 한쪽뿐(반대 방향 근거 미탐색)’이라고 공백을 기록한다. 본문이 간접성·한계를 설명하고 종합을 ‘근거 부족’으로 낮춘 점은 보완적이나, 하위 시장성 판정의 반대 방향 근거 부재는 해소되지 않았다.
- **이해관계자** — 근거 부족: 종합 단계에서 추가 근거가 필요하다고 판단함

표 7. 증거 균형표 (중복 제거 후 수집·검증된 Evidence 수)

구분	DeepSeek-V2 MLA	ITME	HW 베이스라인(InfiniGen·CXL·PNM)
기술 조사·논문 청크	12	26	2
기술 조사·웹 문서	12	4	0
시장·웹 문서	7	5	0
이해관계자·웹 문서	3	3	0
도메인·논문 청크	20	23	0
합계	54	61	2

REFERENCE

- [1] DeepSeek-AI (2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv preprint arXiv:2405.04434, p.4, p.5, p.6, p.7, p.8, p.28, p.31, p.32.
- [2] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J. (SK hynix) (2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv preprint arXiv:2606.12556, p.1, p.2, p.3, p.8, p.9, p.10, p.11.
- [W8] github.com (Wed, 09 Sep 2026 12:00:00 GMT). GitHub - deepseek-ai/FlashMLA: FlashMLA: Efficient Multi-head Latent Attention Kernels · GitHub. github.com, <https://github.com/deepseek-ai/FlashMLA>
- [W3] docs.dynatrace.com (Fri, 28 Aug 2026 00:00:00 GMT). AI Observability integrations — Dynatrace Docs. docs.dynatrace.com, <https://docs.dynatrace.com/docs/observe/dynatrace-for-ai-observability/integrations>
- [W4] docs.vllm.ai (게시일 미확인). mla_attention - vLLM. docs.vllm.ai, https://docs.vllm.ai/en/latest/api/vllm/model_executor/layers/attention/mla_attention
- [W5] docs.vllm.ai (게시일 미확인). Attention Backend Feature Support - vLLM. docs.vllm.ai, https://docs.vllm.ai/en/stable/design/attention_backends
- [W13] news.skhynix.com (Thu, 01 Oct 2026 23:00:00 GMT). SK hynix Presents a Full Lineup of Memory Solutions Optimized for AI Infrastructure at DTF 2026 - SK hynix Newsroom. news.skhynix.com, <https://news.skhynix.com/en/DTF-2026>
- [W22] forbes.com (Sat, 18 Jul 2026 00:00:00 GMT). AI Storage & Memory From Backblaze, CoreWeave, Panmnesia, Vast And Cloudera - Forbes. forbes.com, <https://www.forbes.com/sites/tomcoughlin/2026/07/18/ai-storage--memory-from-backblaze-coreweave-panmnesia-vast-and-cloudera/>
- [W20] esa.int (게시일 미확인). ESA - Technology Readiness Levels (TRL). esa.int, https://www.esa.int/Enabling_Support/Space_Engineering_Technology/Shaping_the_Future/Technology_Readiness_Levels_TRL
- [W29] mordorintelligence.com (Fri, 11 Sep 2026 00:00:00 GMT). Large Language Model Market Size, Growth & Outlook | Industry Report 2031. mordorintelligence.com, <https://www.mordorintelligence.com/industry-reports/large-language-model-llm-market>
- [W27] meticulousresearch.com (Mon, 28 Sep 2026 04:00:00 GMT). MLOps & LLMops Platforms Market Size & Forecast 2036. meticulousresearch.com, <https://www.meticulousresearch.com/product/mlops-llmops-platforms-market-6912>
- [W17] switchboard-ai.com (Wed, 23 Sep 2026 00:00:00 GMT). Switchboard — AI platform for customer operations. switchboard-ai.com, <https://switchboard-ai.com/platform>
- [W26] lmsys.org (게시일 미확인). SGLang v0.3 Release: 7x Faster DeepSeek MLA, 1.5x Faster torch.compile, Multi-Image/Video LLaVA-OneVision - LMSYS Org. lmsys.org, <https://www.lmsys.org/blog/2024-09-04-sglang-v0-3>
- [W23] forbes.com (Tue, 25 Aug 2026 00:00:00 GMT). CXL Growth Shown At The 2026 FMS Conference - Forbes. forbes.com, <https://www.forbes.com/sites/tomcoughlin/2026/08/25/cxl-growth-shown-at-the-2026-fms-conference/>
- [W28] mordorintelligence.com (Tue, 28 Jul 2026 00:00:00 GMT). CXL Memory Controller IC Market Size, Share & 2031 Growth Trends Report. mordorintelligence.com, <https://www.mordorintelligence.com/industry-reports/cxl-memory-controller-ic-market>
- [W2] computeexpresslink.org (게시일 미확인). Breaking Boundaries in Memory: Highlights from AI Infra Summit and SDC 2025 - Compute Express Link. computeexpresslink.org, <https://computeexpresslink.org/blog/breaking-boundaries-in-memory-highlights-from-ai-infra-summit-and-sdc-2025-4198>
- [W16] rocm.docs.amd.com (게시일 미확인). MLA decoding kernel of the AITER library to accelerate LLM inference — Tutorials for AI developers 5.1. rocm.docs.amd.com,

https://rocm.docs.amd.com/projects/ai-developer-hub/en/v5.1/notebooks/gpu_dev_optimize/aiter_mla_decode_kernel.html

- [W14] news.ycombinator.com (게시일 미확인). DeepSeek Open Source FlashMLA - MLA Decoding Kernel for Hopper GPUs | Hacker News. news.ycombinator.com, <https://news.ycombinator.com/item?id=43155023>
- [W15] newsletter.semianalysis.com (게시일 미확인). DeepSeek Debates: Chinese Leadership On Cost, True Training Cost, Closed Model Margin Impacts. newsletter.semianalysis.com, <https://newsletter.semianalysis.com/p/deepseek-debates>
- [W7] finance.yahoo.com (게시일 미확인). The AI 'Memory Wall' Is About to Get a Lot Taller: These 3 Stocks Will Win Big. finance.yahoo.com, <https://finance.yahoo.com/markets/stocks/articles/ai-memory-wall-lot-taller-122127554.html>
- [W31] networkworld.com (게시일 미확인). Chip wafer shortage will run through 2030 as AI demand overwhelms supply: SK Hynix chief | Network World. networkworld.com, <https://www.networkworld.com/article/4146270/chip-wafer-shortage-will-run-through-2030-as-ai-demand-overwhelms-supply-sk-hynix-chief.html>
- [W24] hpcwire.com (게시일 미확인). What Hyperscalers Should Know About CXL. hpcwire.com, <https://www.hpcwire.com/2026/08/20/what-hyperscalers-should-know-about-cxl>
- [D] 판교 9반 2조 (2026). RAG-Design 설계 산출물: KV cache 최적화 기술 다관점 평가 (A-2 문제 상황, A-4 선정 사유, C 평가 기준). 내부 설계 문서.