

KV cache 최적화 기술 다관점 평가 보고서

DeepSeek-V2 MLA(SW 압축) vs ITME(HW 메모리 확장) — 데이터센터·클라우드 장문맥 LLM 서버
판교 9반 2조 · 김동욱, 김민정, 김태동, 박규리, 이재겸, 임동건 · 2026-09-22

SUMMARY

- **TRL(공개정보 추정):** MLA와 ITME 모두 4-6으로 본다. MLA는 DeepSeek-V2 통합·배포 조건 평가, ITME는 CXL-hybrid-memory 기반 평가라는 구현·검증 신호가 있으나, 각 기술 자체의 제품 출시·독립 상용 운영 근거는 부족하다.[1, p.16] [2, p.8]
- **관점의 엇갈림:** MLA는 KV cache 절감과 장문맥 처리의 기술·도메인 신호가 있으나 시장·이해관계자 근거는 부족하다. ITME는 인접 CXL 시장의 성장 신호가 있으나 ITME 자체의 고객 도입·생태계는 확인되지 않아 시장성은 혼재로 판단한다.[1, p.13] [W11] [W13]
- **도메인:** MLA는 메모리 효율에, ITME는 원격 계층을 통한 수용력 확장에 각각 근거가 있다. 다만 두 기술 모두 비용, 운영 안정성 또는 종단간 지연시간의 공개 검증은 제한적이다.[1, p.16] [2, p.6] [2, p.7]
- **관계:** MLA는 모델 내부 KV 표현을 줄이고, ITME는 시스템 메모리 계층을 확장한다. 동일 병목에 대한 서로 다른 계층의 접근이며, 대체재·우열 관계나 결합 효과는 공개 근거만으로 판정할 수 없다.
- **결론:** 단일 추천이나 순위는 도출하지 않는다. 도입 판단은 모델 호환성, CXL·네트워크 구성, 지연시간, 다중 턴 결합, 비용을 해당 운영환경에서 별도로 확인해야 한다.

1. 분석 배경

설계 기준

- KV cache는 생성 단계에서 이전 토큰의 key-value를 저장하여 attention 계산을 가속하는 상태이다. 표준 MHA는 추론 중 모든 key와 value를 캐시해야 하므로, 무거운 KV cache가 배치 크기와 시퀀스 길이를 제한하는 병목이 될 수 있다.[1, p.7]
- 본 평가의 도메인은 데이터센터·클라우드 기반 장문맥 LLM 서버이다. 설계 기준상 이 환경에서는 대규모 동시 요청, 비용 민감성, 문맥 길이 민감성이 함께 존재하며, KV cache가 HBM을 점유하면 동시 요청 수와 최대 batch의 제약, 장문맥 요청 제한, 데이터 이동·재계산 부담이 나타날 수 있다.
- 장문맥 서버에서 KV cache 문제는 모델 내부 표현량과 GPU 밖 계층으로의 저장·이동 문제를 함께 포함한다. CPU 메모리 오프로드는 배치 크기·시퀀스 길이 제약을 완화할 수 있으나, attention 계산을 위한 대용량 KV cache 전송은 PCIe 대역폭 병목을 유발할 수 있다.[3, p.4]
- 따라서 본 보고서는 하나의 수치로 우열을 정하지 않는다. MLA는 attention 구조 계층, ITME는 원격 메모리·데이터 이동 계층에서 작동하므로, TRL·시장성·이해관계자·도메인 적용성의 근거 수준과 제약을 분리해 비교한다.

표 1. KV cache 규모 예시 (Llama-3.1-70B, FP16, 토큰당 320KiB — 설계 산출물 A-2 산식)

문맥 길이	요청 1건 KV cache	동시 8건	GPU HBM 80GB 대비(1건)
8K	2.5 GiB	20 GiB	3%
128K	40 GiB	320 GiB	50%
1M	320 GiB	2,560 GiB	400%

2. 기술 선정

선정 방식

- 2안(Human 기반, 조 토의 후 직접 선정)을 적용했다. 이는 조사 결과가 아니라 과제의 설계 기준이다.
- 선정 기준은 데이터센터·클라우드 장문맥 LLM 서버의 KV cache 병목과의 직접성, 서로 다른 작동 계층의 비교 가능성, 공개 문헌에서 확인 가능한 구현·평가 근거의 존재였다.

DeepSeek-V2 MLA 선정

- MLA는 저랭크 key-value 공동 압축으로 추론 시 KV cache 병목을 줄이도록 설계된 attention 메커니즘이다. [1, p.6]
- 표준 MHA가 key와 value를 모두 캐시하는 것과 달리, MLA는 압축된 KV latent를 캐시하는 구조를 제시한다. [1, p.7]
- 따라서 모델 내부에서 KV 표현량 자체를 줄이는 SW·모델 아키텍처 접근의 사례로 선정했다.

ITME 선정

- ITME는 SSD-backed 용량을 CXL-hybrid-memory 기반 원격 메모리 서버로 제시하여, 대규모 KV cache와 가중치의 계층 배치를 다루는 시스템 접근이다.[2, p.3] [2, p.4]
- GPU 연산과 원격 계층 데이터 검색의 중첩을 통해 접근 지연을 숨기는 구성을 제시한다.[2, p.8]
- 따라서 GPU 메모리 바깥의 용량 확장과 데이터 이동을 다루는 HW·시스템 계층 사례로 선정했다.

비선정 후보

- InfiniGen과 CXL-PNM은 ITME 한계의 교차 확인을 위한 베이스라인 문헌으로 활용했다. CPU 오프로드의 PCIe 병목과 CXL near-memory 처리라는 상이한 접근을 확인할 수 있다.[3, p.4] [4, p.4]
- 이들의 비선정 사유는 기술 사실의 단정이 아니라, 본 과제에서 MLA와 ITME를 대표 사례로 직접 선정한 **설계 판단**이다.

표 2. 비선정 후보와 사유 (설계 산출물 A-4)

후보	진영	비선정 사유	RAG 문서 활용
InfiniGen	HW	호스트 메모리 오프로딩으로 신규 메모리 인프라 없이 SW 관리 성격이 강함	O (ITME 비교용 베이스라인)
CXL-PNM	HW	연산까지 메모리 측으로 옮기는 확장형 접근으로, '공간 확장' 자체의 대표성은 ITME가 더 직접적	O (ITME 비교용 베이스라인)
KIVI	SW	사후 양자화의 대표 베이스라인이나 공개 채택 근거가 연구·라이브러리 수준	X (선정 검토만)
TurboQuant	SW	재학습 없이 적용 가능한 최신 양자화이나 공식 상용화 근거가 제한적	X (선정 검토만)

3. 기술 개요

구분	DeepSeek-V2 MLA	ITME
진영	SW·모델 아키텍처	HW·시스템 메모리 계층
작동 계층	Transformer attention 내부	원격 CXL-hybrid-memory 및 데이터 이동 경로
핵심 접근	저랭크 key-value 공동 압축	원격 메모리 확장과 계층 간 데이터 배치·검색
저자 보고 효과	KV cache 축소 및 배포 처리량 결과 보고	원격 계층 기반 처리량 결과 보고
전제조건	MLA를 포함한 모델 아키텍처	CXL-hybrid-memory, 원격 메모리·전송 경로 구성
한계·확인사항	기존 MHA 자산 전환, 지연시간·운영성 공개 근거 부족	장기 다중 턴 I/O 경합, 품질·비용·상용 배포 근거 부족

DeepSeek-V2 MLA

- **핵심 접근(fact):** MLA는 low-rank key-value joint compression을 이용해 추론 시 KV cache 병목을 줄이도록 설계되었다.[1, p.6] MHA에서는 key와 value 전체를 캐시해야 하지만, MLA는 압축 KV latent를 캐시하는 구조를 제시한다.[1, p.7]
- **저자 보고 효과(fact):** DeepSeek-V2는 128K 토큰 문맥 길이를 지원하며, 저자들은 DeepSeek 67B 대비 KV cache 93.3% 감소를 보고했다.[1, p.1] 서비스 배포에서는 FP8 파라미터와 평균 6비트 KV cache 양자화를 사용했으며, 처리량 결과는 이 배포 조건 전체의 결과로 해석해야 한다.[1, p.16]
- **한계·전제조건(interpretation):** MLA 효과를 기존 MHA checkpoint에 사후 적용할 수 있는지, 재학습이 필요한지, 서빙 프레임워크가 직접 지원하는지는 제공 근거만으로 확인할 수 없다. MLA 단독 효과와 DeepSeek-V2 전체 모델·양자화·하드웨어 조건의 효과도 분리되어 있지 않다.

ITME

- **핵심 접근(fact):** ITME는 SSD-backed 용량을 직접 접근 가능한 메모리 확장으로 제시하며, CXL-hybrid-memory 기반 원격 메모리 서버로 동작하도록 설명한다.[2, p.3] 하드웨어 관리 DRAM cache로 backend read latency를 완화하는 hybrid 설계를 제시한다.[2, p.4]
- **저자 보고 효과(fact):** 저자들은 NVMe-oF 기반 분리형 스토리지 기준선 대비 1.80배 처리량을 보고했다.[2, p.2] 원격 CXL-hybrid-memory에서 가중치와 prefix KV cache를 검색하는 작업을 GPU 계산과 겹쳐 지연을 은닉하는 방식을 제시한다.[2, p.8]
- **한계·전제조건(fact 및 interpretation):** ITME는 원격 계층 접근, staging, prefetch 정책에 의존한다. 읽기·쓰기 경합은 유효 읽기 대역폭을 낮추고 예측하기 어려운 latency excursion을 만들 수 있어, 논문은 읽기 우선 I/O 스케줄링을 제시한다.[2, p.6] 구체적인 고객 운영, 제품 출하, 장문맥 품질, 총소유비용은 공개 근거 부족이다.

4. 관점별 평가

4.1 기술 성숙도(TRL)

기술	TRL 추정(공개 정보 기반)	판단 근거 요약
DeepSeek-V2 MLA	technology_trl: 4-6 (추정). 근거: MLA는 DeepSeek-V2에 통합되어 구현되었고, 저자 보고 기준 서비스 배포 설정...	fact: MLA는 low-rank key-value joint compression으로 추론 시 KV-cache 병목을 제거하도록 설계되었다([1, p.6]). 추론 중 압축 KV latent만 캐시하며, key/value up-projection은 query/output projection에 흡수될 수 있다([1, p.7]). 저자 보고 기준 DeepSeek-V2는 DeepSeek 67B 대비 KV cache 93.3% 감소를 보고했다([1, p.1])....
ITME	technology_trl: 4-6 (추정). 근거: FPGA 기반 하드웨어 프로토타입의 기능 실현 가능성 시연과 생산급 SK hynix CM...	fact: ITME는 TB-scale LLM 워크로드를 위한 CXL-hybrid-memory 확장 구조로, GPU 서버가 RDMA를 통해 원격 계층의 모델 가중치와 KV cache에 접근하도록 한다([2, p.2]). 하드웨어 prefetcher와 사용자 수준 prefetch API를 포함하며, FPGA 기반 하드웨어 프로토타입으로 기능 가능성을 시연했다고 저자들이 보고했다([2, p.2]). 저자 보고 기준 NVMe-oF 분리형 스토리지 기준선 대비 처리량...

판정 기준과 범위

- TRL은 설계 기준에 따라 논문·특허 근거를 1-3, 코드·도구 탑재 등 구현 근거를 4-6, 제품 출시·상용 서비스 적용 발표를 7-9의 신호로 본다.
- 아래 판단은 공식 TRL 인증이 아니라 논문, 공개 발표, 상용화 공지의 공개정보에만 기초한 추정이다.

DeepSeek-V2 MLA — 4-6 추정

- **fact:** MLA는 DeepSeek-V2의 Transformer attention에 통합된 구조로 제시되며, 저자들은 서비스 배포를 위해 FP8 파라미터와 평균 6비트 KV cache 양자화를 사용했다고 보고했다.[1, p.4] [1, p.16]
- **fact:** 동일 논문은 128K 문맥 평가에서 견고한 성능을 보고한다.[1, p.13]
- **judgment:** 통합 구현과 배포 조건 평가가 문서화되어 있어 4-6으로 추정한다. 다만 MLA 아키텍처 자체의 제품 출시, 독립 고객 도입, 상용 서비스 운영을 확인하는 공개 근거가 없으므로 7-9는 판정하지 않는다.
- **계열과의 구분:** attention/KV-cache 최적화 계열 전체의 TRL은 별도 제품·운영 근거가 없어 근거 부족이다. DeepSeek 모델의 공개·사용과 MLA 기능 자체의 직접 상용 지원은 동일하지 않다.

ITME — 4-6 추정

- **fact:** ITME는 CXL-hybrid-memory를 통한 원격 메모리 확장 구조와, GPU 계산 및 원격 계층 검색의 중첩을 제시한다.[2, p.3] [2, p.8]
- **fact:** 저자들은 ITME의 처리량 평가 결과를 보고한다.[2, p.2]
- **judgment:** 아키텍처와 평가가 공개되어 있어 ITME 개별 기술은 4-6으로 추정한다. 그러나 ITME 정확 아키텍처의 제품 출시, 고객 배포, 상용 서비스 운영을 문서화하는 공개 근거가 부족하므로 7-9는 판정하지 않는다.
- **계열과의 구분:** CXL은 메모리 확장·폴링의 핵심 기술로 논의되지만, 상용 CXL 하드웨어의 제한된 가용성 때문에 다수 연구가 시뮬레이션·에뮬레이션에 의존했다고 서술된다.[2, p.11] 이는 CXL 일반 또는 CXL 메모리 모듈의 TRL을 ITME 개별 기술에 그대로 부여할 근거가 아니다.

공개정보 공백

- MLA와 ITME 모두 TRL 4-6 이후의 비공개 통합, 고객 검증, 장애·운영 지표는 확인할 수 없다. 공개 근거 부족은 미도입의 증명이 아니다.

4.2 시장성

평가 대상	DeepSeek-V2 MLA	ITME
시장 규모·성장성	근거 부족	긍정
상용화·채택 현황	근거 부족	근거 부족
생태계 지지	근거 부족	근거 부족
종합	근거 부족	근거 부족
근거	[W7] [W6]	[W11] [W13]

DeepSeek-V2 MLA — 근거 부족

- **시장 규모·성장(fact):** MLA 또는 MLA가 속한 SW 추론 최적화 시장의 시장 규모, 기준연도, 전망연도, CAGR을 직접 제시하는 검증된 자료는 제공되지 않았다.
- **채택(fact):** 제공된 DeepSeek 관련 시장 보도는 기업가치·자금조달 맥락의 정보이며, MLA 기능 자체의 유료 서비스 적용, 고객 도입 또는 장문맥 서빙 채택을 식별하지 않는다.[W6] [W7]
- **생태계(judgment):** vLLM·SGLang·클라우드 서비스·공식 저장소가 MLA를 직접 지원한다는 공개 근거가 부족하다. DeepSeek 모델의 사용 또는 기업 관련 보도는 MLA 기능의 독립 지원 사례로 해석하지 않는다.
- **판정:** 시장성은 근거 부족이다. 필요한 확인 자료는 MLA 직접 지원 릴리스 노트, 고객·운영 사례, SW 추론 최적화 시장의 정의된 조사자료다.

ITME — 혼재

- **인접 시장 신호(fact):** CXL 메모리 컨트롤러 IC 시장 자료는 초기 상업적 배치와 시장 성장 전망을 다룬다. [W11] 이는 CXL 관련 시장 환경의 신호이지만 ITME 자체 시장의 수치가 아니다.

- **개별 기술 채택(fact):** ITME 관련 보도는 SK hynix의 AI 메모리 아키텍처 진전 맥락을 언급하지만, ITME의 제품 출하, 고객명, 운영 규모, 실제 서비스 적용을 직접 확인하지 않는다.[W13]
- **생태계(judgment):** ITME를 직접 지원하는 추론 엔진, 클라우드, 서버 OEM, CXL 장치 또는 표준화 문서의 공개 근거가 부족하다.
- **판정:** 인접 CXL 시장의 긍정 신호와 ITME 개별 상용화 근거 부족이 공존하므로 시장성은 **혼재**다. CXL 일반 시장 규모로 ITME의 수요·매출·도입을 대체할 수 없다.

4.3 이해관계자

평가 대상	DeepSeek-V2 MLA	ITME
경쟁 진영	근거 부족	근거 부족
도입 기업·개발자	근거 부족	근거 부족
투자 업계	근거 부족	근거 부족
종합	근거 부족	근거 부족
근거	[W2]	[W5] [W4] [W1]

평가 범위

- S1은 경쟁 기술·기업, S2는 개발자·도입·운영자, S3는 투자자·애널리스트의 기술 **직접 발언** 또는 **운영 경험**을 요구한다.
- 제공된 웹 자료 중 일부는 기술 일반 설명 또는 제3자 논평이므로, 직접 이해관계자 평가와 구분한다.

DeepSeek-V2 MLA — 근거 부족

- **S1 경쟁 기술·기업:** MLA를 직접 대상으로 장점·제약·대체 관계를 밝힌 경쟁사 또는 대체기술 제공자의 귀속 발언은 확인되지 않았다.
- **S2 개발자·도입자:** PyTorch 한국 사용자 모임 자료는 MLA의 KV cache 절감 구조와 사용 방법을 소개하지만, 특정 기업의 실제 운영 도입 경험이나 재현 가능한 운영 성과는 아니다.[W2]
- **S3 투자자·애널리스트:** MLA 자체의 수익성, 채택성, 위험을 직접 평가한 투자자·애널리스트 발언은 확인되지 않았다.
- **판정:** S1-S3 모두 근거 부족이며, 전체 이해관계자 관점도 근거 부족이다.

ITME — 근거 부족

- **S1 경쟁 기술·기업:** ITME 자체를 대상으로 한 경쟁사 또는 대체기술 제공자의 공식 평가 발언은 확인되지 않았다.
- **S2 개발자·도입자:** CXL 일반 설명 자료는 DDR·PCIe의 제약과 CXL 풀링을 설명하지만, ITME의 실제 통합·운영 경험은 아니다.[W4] ITME 관련 소개 페이지의 성능 서술도 도입기업의 독립 운영 평가로 볼 수 없다.[W8]
- **S3 투자자·애널리스트:** 메모리·HBM 경쟁에 관한 인용은 ITME의 성장성이나 사업성을 직접 평가한 발언이 아니다.[W1] CXL 일반에 관한 업계 콘텐츠 역시 ITME에 대한 투자자 판단으로 사용할 수 없다.[W5]
- **판정:** S1-S3 모두 근거 부족이며, 전체 이해관계자 관점도 근거 부족이다.

해석상 주의

- 위의 [W1]-[W5], [W8]은 배경 또는 간접 신호일 뿐이다. ITME 개별 기술의 도입·운영·투자자 의견으로 환원하지 않았다.

4.4 도메인 적용성(D1-D7)

평가항목	MLA 판정	MLA 근거	ITME 판정	ITME 근거
ITME D1 워크로드 수용 능력	근거 부족	-	적합	-

평가항목	MLA 판정	MLA 근거	ITME 판정	ITME 근거
ITME D2 서비스 성능	근거 부족	-	조건부	-
ITME D3 메모리 자원 효율성	근거 부족	-	적합	-
ITME D4 품질·정보 보존	근거 부족	-	근거 부족	-
ITME D5 운영 안정성	근거 부족	-	조건부	-
ITME D6 도입·확장 용이성	근거 부족	-	조건부	-
ITME D7 비용 효율성	근거 부족	-	조건부	-
MLA D1 워크로드 수용 능력	적합	-	근거 부족	-
MLA D2 서비스 성능	조건부	-	근거 부족	-
MLA D3 메모리 자원 효율성	적합	-	근거 부족	-
MLA D4 품질·정보 보존	적합	-	근거 부족	-
MLA D5 운영 안정성	근거 부족	-	근거 부족	-
MLA D6 도입·확장 용이성	조건부	-	근거 부족	-
MLA D7 비용 효율성	조건부	-	근거 부족	-

DeepSeek-V2 MLA

- **D1 워크로드 수용 능력 — 적합:** DeepSeek-V2는 128K 토큰 문맥을 지원한다고 제시되며, 저자 보고 기준 KV cache 93.3% 감소가 제시된다.[1, p.1] 단, 최대 동시 요청 수와 최대 batch는 공개 근거 부족이다.
- **D2 서비스 성능 — 조건부:** 저자들은 배포 조건에서 처리량 결과를 보고했다.[1, p.16] 그러나 TTFT, 종단간 지연시간, 백분위 지연시간이 제공되지 않아 처리량 결과만으로 응답시간 품질을 확정할 수 없다.
- **D3 메모리 자원 효율성 — 적합:** MLA는 추론 시 압축 KV latent를 캐시하는 구조이며, 배포에서는 평균 6비트 KV cache 양자화가 사용되었다.[1, p.7] [1, p.16] 다만 HBM·호스트 DRAM·외부 계층별 사용량은 근거 부족이다.
- **D4 품질·정보 보존 — 조건부:** 128K에서의 견고한 결과는 DeepSeek-V2 전체 모델의 결과로 보고되었다.[1, p.13] MLA 단독의 인과 효과로 분리되지 않았으므로 조건부로 판단한다.
- **D5 운영 안정성 — 근거 부족:** 다중 턴 동시성, cache miss, 자원 경합, tail latency 및 성능 변동의 운영 지표가 부족하다.
- **D6 도입·확장 용이성 — 조건부:** MLA는 Transformer attention 구조에 통합된 방식이다.[1, p.4] 기존 MHA 모델의 checkpoint 변환·재사용 및 재학습 요건은 공개 근거 부족이다.
- **D7 비용 효율성 — 조건부:** KV cache 절감은 GPU 메모리 자원 절감 가능성을 시사하지만, 동등 워크로드 기준 비용·TCO·달러당 처리량의 직접 근거는 없다.[1, p.1] [1, p.16]

ITME

- **D1 워크로드 수용 능력 — 적합:** ITME 평가는 다중 턴 대화와 KV cache 메모리 압력 조건을 포함한다.[2, p.9] 다만 최대 지원 동시 요청·문맥 길이의 일반화 가능한 한계는 근거 부족이다.
- **D2 서비스 성능 — 조건부:** 저자들은 NVMe-oF 기준선 대비 처리량 결과를 보고했다.[2, p.2] 그러나 절대 TTFT, 종단간 지연시간, 백분위 지연시간이 부족하다.
- **D3 메모리 자원 효율성 — 적합:** ITME는 원격 CXL-hybrid-memory 계층에 대용량 상태를 배치하고, GPU 계산과 검색을 중첩하는 구조를 제시한다.[2, p.3] [2, p.8] 계층별 총 사용량과 토큰당 KV byte는 근거 부족이다.
- **D4 품질·정보 보존 — 근거 부족:** 원격 KV 저장·복원 및 prefetch가 생성 품질이나 장문맥 정보 보존에 미치는 영향을 직접 측정한 공개 결과가 없다.
- **D5 운영 안정성 — 조건부:** KV cache miss는 GPU 재계산으로 처리하도록 설계되었다.[2, p.7] 읽기·쓰기 경합은 읽기 대역폭 저하와 예측하기 어려운 latency excursion을 유발할 수 있어, 읽기 우선 I/O 정책이 제시된

다.[2, p.6]

- **D6 도입·확장 용이성 — 조건부:** CXL-hybrid-memory 원격 서버, 계층 간 staging 및 전송 경로가 필요한 구조다.[2, p.3] [2, p.4] 구체적 장비 호환성, 네트워크 토폴로지, 프레임워크 변경 범위는 근거 부족이다.
- **D7 비용 효율성 — 조건부:** 메모리 확장을 비용 효율적으로 지향하는 구조이나, ITME 인프라의 TCO, 요청당 비용, 동등 워크로드 비용 비교는 제공되지 않았다.[2, p.1] [2, p.8]

판정 연결

- 위 D1-D7 판정은 본 절의 인용 근거를 요약한 것이다. MLA D4는 모델 전체 결과와 MLA 단독 효과를 분리할 수 없으므로 일관되게 **조건부**로 둔다.

5. 종합 의견

관점 매트릭스

관점	DeepSeek-V2 MLA	ITME
TRL	4-6 추정: 통합·배포 조건 평가가 있으나 상용 채택 근거 부족	4-6 추정: 공개 아키텍처·평가가 있으나 제품·고객 운영 근거 부족
시장성	근거 부족: MLA 자체 시장·채택·생태계 자료 부족	혼재: 인접 CXL 시장 신호는 있으나 ITME 개별 채택 부족
이해관계자	근거 부족: S1-S3 직접 발언 부족	근거 부족: S1-S3 직접 발언 부족
도메인	메모리 효율은 적합, 성능·도입·비용은 조건부, 운영성은 근거 부족	수용력·메모리 효율은 적합, 성능·운영·도입·비용은 조건부, 품질은 근거 부족

관점 간 일치

- 두 기술 모두 구현·평가 신호는 있으나, 개별 기술의 상용 출시·독립 고객 채택 근거가 부족하다. 따라서 TRL 7-9로 확장하지 않는다는 점에서 TRL·시장 판단이 일치한다.[1, p.16] [2, p.8]
- 두 기술 모두 KV cache 관련 메모리 병목 완화 근거는 있으나, 동등 워크로드 기준 비용과 TCO가 부족하다. 메모리 절감 또는 처리량 결과만으로 경제성을 확정하지 않는다는 점에서 도메인 판단이 일치한다.[1, p.16] [2, p.2]
- 두 기술 모두 처리량 관련 저자 보고는 있으나, 운영 판단에 필요한 절대 TTFT·종단간·백분위 지연시간의 공개 근거는 제한적이다.[1, p.16] [2, p.6]

MLA의 관점 간 상충

쟁점	관점 A 평가	관점 B 평가	엇갈리는 이유
통합 검증과 시장 채택	TRL·도메인: 통합 구조와 배포 조건 결과가 있어 긍정 신호	시장: MLA 자체의 고객 도입·생태계는 근거 부족	논문 내 평가와 독립 제품·고객 검증은 서로 다른 증거를 요구한다.
메모리 효율과 전환 용이성	D3: 압축 KV cache 구조로 적합	D6: 기존 MHA 자산 전환은 조건부	운용 중인 MLA 모델의 효율과 기존 모델을 MLA로 전환하는 난이도는 별개다.

ITME의 관점 간 상충

쟁점	관점 A 평가	관점 B 평가	엇갈리는 이유
CXL 시장 환경과 ITME 상용화	시장 환경: 인접 CXL 시장 성장 신호	TRL·시장 채택: ITME 개별 제품·고객 근거 부족	CXL 일반 시장과 특정 ITME 아키텍처의 상용화는 동일하지 않다.
메모리 확장과 장기 운영성	D1·D3: 원격 계층 수용력·메모리 효율에 적합	D5: I/O 경험에 따라 조건부	용량 확장 효과는 staging·prefetch·읽기/쓰기 경험 제어에 의존한다.[2, p.6] [2, p.7]

두 접근의 관계

- **interpretation:** MLA는 GPU에 저장되는 KV 표현량을 줄이고, ITME는 GPU 밖 계층의 저장 용량과 이동 경로를 다룬다.[1, p.6] [2, p.3]
- 따라서 두 접근은 경쟁적 단일 대안이라기보다 보완 가능한 계층 접근으로 해석할 수 있다. 다만 두 기술의 결합 시 메모리 절감 중복, 지연시간 상호작용, 품질 영향, 비용 효과를 직접 검증한 근거는 없으므로 결합 효과는 근거 부족이다.

6. 시사점

관점에 따라 달라지는 평가

- 모델 개발 관점에서는 MLA의 KV 표현 압축이 직접적인 메모리 효율 신호가 될 수 있으나, 기존 MHA 모델 전환성과 MLA 단독 품질 효과는 별도 검증이 필요하다.[1, p.6] [1, p.13]
- 인프라 관점에서는 ITME가 원격 계층 확장 선택지를 제공하지만, 성능은 prefetch-staging-읽기/쓰기 경합 관리에 조건부로 의존한다.[2, p.6] [2, p.7]
- 시장 관점에서는 DeepSeek 모델 관련 보도와 CXL 인접 시장 자료가 존재하더라도, 이는 각각 MLA와 ITME의 직접 채택 증거가 아니다.[W6] [W11]

이해관계자별 도입 전 확인 과제

이해관계자	MLA 확인 과제	ITME 확인 과제
클라우드 사업자	장문맥·동시성별 TTFT, 종단간·tail latency, 서빙 엔진 지원 여부	CXL·RDMA·NIC 토폴로지, staging 용량, 경합 시 tail latency, 장애 격리
모델 개발사	기존 MHA checkpoint 호환성, 재학습 필요 여부, MLA 단독 품질 검증	원격 KV 복원·재계산이 품질과 스케줄링에 미치는 영향
메모리·HW 벤더	MLA 워크로드에서의 KV 절감이 실제 메모리 요구량에 미치는 효과	장치 호환성, 읽기 우선 정책, CXL 계층·네트워크 병목, 장기 I/O 내구성
투자자	MLA 기능 자체의 유료 도입, 고객 유지, 생태계 지원 자료	ITME 제품화 상태, 고객 검증, 공급망, TCO 및 대체 메모리 계층과의 비교

- 위 과제는 추천 조건이 아니라 공개 근거의 공백을 해소하기 위한 검증 항목이다. 특히 비용은 두 기술 모두 동등 워크로드 기준으로 확인해야 하며, 서로 다른 모델·하드웨어·기준선의 저자 보고 수치를 직접 비교해서는 안 된다.

7. 한계점

공개정보와 TRL의 한계

- 모든 TRL 판정은 논문, 특허, 상용 발표 등 공개정보에만 기초한 추정이며, 공식 TRL 인증이 아니다.
- 논문 발표·기술 공개와 실제 고객 채택·운영 사이에는 시차가 있을 수 있다. 공개 채택 근거가 없다는 사실은 기술 또는 제품의 부재를 의미하지 않는다.
- TRL 4-6 구간에서는 비공개 통합, 고객 평가, 장애율, 운영 비용, 장기 안정성 정보가 공개되지 않는 공백이 크다. MLA와 ITME 모두 7-9 판정에 필요한 제품 출시·상용 운영 자료가 부족하다.

수치와 적용 범위의 한계

- MLA와 ITME의 정량 결과는 저자 보고 기준이며, 모델, 하드웨어, 정밀도, 기준선, 워크로드와 측정 조건이 다르다. 따라서 수치를 같은 단위의 직접 우열 비교로 사용할 수 없다.[1, p.16] [2, p.2]
- MLA의 배포 결과에는 모델 전체 구조와 양자화 조건이 함께 포함되어 있어 MLA 단독 효과로 분리할 수 없다.[1, p.16]

- ITME는 원격 계층의 읽기·쓰기 경합 및 cache miss 처리 정책의 영향을 받는다.[2, p.6] [2, p.7] 품질 보존, 장기 다중 턴 안정성, TCO의 직접 근거는 부족하다.

확증편향 방지 조치와 남은 한계

조치	실제 적용 내용	남은 한계
HW 베이스라인 교차 확인	InfiniGen과 CXL-PNM 문헌을 사용해 CPU 오프로드의 PCIe 병목과 CXL near-memory 접근을 확인했다.[3, p.4] [4, p.4]	이는 ITME의 직접 우위 또는 한계의 정량 증명이 아니다.
동일 형식 병기	두 기술을 쟁점·관점 A·관점 B·이유 형식으로 병기했다.	증거량과 공개 범위 자체의 비대칭은 해소되지 않는다.
종합 단계의 증거 제한	종합 판단은 이미 검증된 Evidence만 사용하고 신규 검색·신규 수치를 추가하지 않았다.	제공된 Evidence의 원문 발췌 범위와 자료 시점에 의존한다.

- 시장성·이해관계자 평가는 특히 직접 근거가 부족하다. MLA 기능 자체와 DeepSeek 모델 일반, ITME 개별 기술과 CXL 일반 시장을 구분했으나, 이 구분으로 인해 다수 항목은 근거 부족으로 남는다.
- 본 보고서는 순위, 우승 기술 또는 단일 추천을 제시하지 않는다.

REFERENCE

- DeepSeek-AI(게시일 미확인). DeepSeek-V2. 원문 PDF.
- ITME 저자 미확인(게시일 미확인). ITME 관련 원문 PDF. 원문 PDF.
- InfiniGen 저자 미확인(게시일 미확인). InfiniGen 관련 원문 PDF. 원문 PDF.
- CXL-PNM 저자 미확인(게시일 미확인). CXL-PNM 관련 원문 PDF. 원문 PDF.
- TechCrunch(2026-05-06). DeepSeek could hit \$45B valuation from its first investment round. TechCrunch, <https://techcrunch.com/2026/05/06/deepseek-could-hit-45b-valuation-from-its-first-investment-round/>
- TechCrunch(2026-07-14). DeepSeek reportedly in talks to raise \$1.5B, then IPO. TechCrunch, <https://techcrunch.com/2026/07/14/deepseek-reportedly-in-talks-to-raise-1-5b-then-ipo/>
- Mordor Intelligence(게시일 미확인). CXL Memory Controller IC Market. Mordor Intelligence, <https://www.mordorintelligence.com/industry-reports/cxl-memory-controller-ic-market>
- TrendForce(2026-09-18). OpenAI, Intel Reportedly Downplay CXL as HBM Replacement, Citing Use-Case and Data-Transfer Limits. TrendForce, <https://www.trendforce.com/news/2026/09/18/news-openai-intel-reportedly-downplay-cxl-as-hbm-replacement-citing-use-case-and-data-transfer-limits>
- PyTorch 한국 사용자 모임(게시일 미확인). DeepSeek-V2 MoE. <https://discuss.pytorch.kr/t/deepseek-v2-moe/4366>
- HyperAccel(게시일 미확인). What is CXL. HyperAccel, <https://hyper-accel.github.io/posts/what-is-cxl>
- AlphaXiv(게시일 미확인). ITME 관련 논문 소개 페이지. AlphaXiv, <https://www.alphaxiv.org/abs/2606.12556>
- 주간조선(게시일 미확인). CXMT·HBM 경쟁 관련 기사. 주간조선, <http://weekly.chosun.com/news/articleView.html?idxno=40084>
- 삼성전자 반도체 뉴스룸(게시일 미확인). AI 반도체 시장의 미래를 엿보다: CXL에 대해. 삼성전자 반도체 뉴스룸, <https://news.samsungsemiconductor.com/kr/behind-the-chip-ai-%EB%B0%98%EB%8F%84%EC%B2%B4-%EC%8B%9C%EC%9E%A5%EC%9D%98-%EB%AF%B8%EB%9E%98%EB%A5%BC-%EC%97%BF%EB%B3%B4%EB%8B%A4-cxl%EC%97%90-%EB%8C%80%ED%95%B4>

표 7. 증거 균형표 (중복 제거 후 수집·검증된 Evidence 수)

구분	DeepSeek-V2 MLA	ITME	HW 베이스라인(InfiniGen·CXL-PNM)
기술 조사 · 논문 청크	36	47	5
시장 · 웹 문서	4	2	0
이해관계자 · 웹 문서	2	5	0
도메인 · 논문 청크	37	44	0
합계	79	98	5

REFERENCE

- [1] DeepSeek-AI (2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv preprint arXiv:2405.04434, p.1, p.4, p.6, p.7, p.13, p.16.
- [2] Jang, H., Min, Y., Kim, S., Ahn, T., Kim, H., Joo, Y., Kim, H., & Kim, J. (SK hynix) (2026). ITME: Inference Tiered Memory Expansion with Disaggregated CXL-Hybrid Memories. arXiv preprint arXiv:2606.12556, p.1, p.2, p.3, p.4, p.6, p.7, p.8, p.9, p.11.
- [3] Lee, W., Lee, J., Seo, J., & Sim, J. (Seoul National University) (2024). InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management. arXiv preprint arXiv:2406.19707, p.4.
- [4] Kim, D., Lee, M., Kim, J., Kwon, H., Jeong, H., Park, S.-S., et al. (Hanyang University, Samsung Electronics) (2025). Scalable Processing-Near-Memory for 1M-Token LLM Inference: CXL-Enabled KV-Cache Management Beyond GPU Limits. arXiv preprint arXiv:2511.00321, p.4.
- [W11] mordorintelligence.com (Tue, 28 Jul 2026 00:00:00 GMT). CXL Memory Controller IC Market Size, Share & 2031 Growth mordorintelligence.com, <https://www.mordorintelligence.com/industry-reports/cxl-memory-controller-ic-market>
- [W13] trendforce.com (Fri, 18 Sep 2026 04:00:00 GMT). [News] OpenAI, Intel Reportedly Downplay CXL as HBM Replacement, Citing Use-Case and Data-Transfer Limits. trendforce.com, <https://www.trendforce.com/news/2026/09/18/news-openai-intel-reportedly-downplay-cxl-as-hbm-replacement-citing-use-case-and-data-transfer-limits>
- [W7] techcrunch.com (Tue, 14 Jul 2026 16:45:23 GMT). DeepSeek reportedly in talks to raise \$1.5B, then IPO - TechCrunch. techcrunch.com, <https://techcrunch.com/2026/07/14/deepseek-reportedly-in-talks-to-raise-1-5b-then-ipo/>
- [W6] techcrunch.com (Wed, 06 May 2026 17:20:34 GMT). DeepSeek could hit \$45B valuation from its first investment round - TechCrunch. techcrunch.com, <https://techcrunch.com/2026/05/06/deepseek-could-hit-45b-valuation-from-its-first-investment-round/>
- [W2] discuss.pytorch.kr (게시일 미확인). DeepSeek-V2: 강력하고 경제적이며 효율적인 전문가 혼합 discuss.pytorch.kr, <https://discuss.pytorch.kr/t/deepseek-v2-moe/4366>
- [W5] news.samsungsemiconductor.com (게시일 미확인). [Behind the CHIP] AI 반도체 시장의 미래를 엿보다. CXL에 news.samsungsemiconductor.com, <https://news.samsungsemiconductor.com/kr/behind-the-chip-ai-%EB%B0%98%EB%8F%84%EC%B2%B4-%EC%8B%9C%EC%9E%A5%EC%9D%98-%EB%AF%B8%EB%9E%98%EB%A5%BC-%EC%97%BF%EB%B3%B4%EB%8B%A4-cxl%EC%97%90-%EB%8C%80%ED%95%B4>
- [W4] hyper-accel.github.io (게시일 미확인). AI 시대의 필수 소비재, 메모리 이해하기 4편: CXL 이해하기. hyper-accel.github.io, <https://hyper-accel.github.io/posts/what-is-cxl>

- [W1] weekly.chosun.com (게시일 미확인). 미국 압력과 중국 추격... K반도체, CXL로 대응한다 - 주간조선. weekly.chosun.com, <http://weekly.chosun.com/news/articleView.html?idxno=40084>
- [W8] alphaxiv.org (게시일 미확인). ITME: Inference Tiered Memory Expansion with alphaxiv.org, <https://www.alphaxiv.org/abs/2606.12556>